Master's Thesis

Teil 1/4 - Problem Space

RAG ingestion framework: Standardizing the fusion of heterogeneous structured and un-structured enterprise data

Submitted by
Patrick Roith, BSc.

Desired Academic Title:
Master of Science

Master Program	Digital Technology & Innovation
Matriculation Number	01352706
Class of	2026
Supervisor	TBA

I hereby confirm that

- I wrote this paper on my own, did not use any other sources or tools than those mentioned and did not make use of any other unauthorized support,
- those parts of the paper taken out of other papers by either direct quote or paraphrase (including online sources and AI-based tools) have been marked accordingly, stating the source,
- this paper has not been submitted as an examination paper either in Austria or abroad,
- this paper corresponds to the version previously submitted to the supervisor and uploaded for the plagiarism check.

I further confirm that any tools and technologies employed in the process of researching and writing this paper, including various AI tools and software, were used transparently, responsibly and solely as a means of support. I critically reflected upon the findings gained in this process, embedding them in the scientific discourse of my paper.

I confirm that I adhered to the rules of good scientific practice and checked the contents for their ethical integrity, correctness, reliability and verifiability.

Vienna, November 14, 2025.	Patrick Roith
Place, date	Author's name

Abstract

This master's thesis addresses a challenging problem shared by numerous organizations, including my current company, namely the inability to standardize the ingestion of both structured and unstructured data for advanced analytical tasks. Specifically, the structured and unstructured data are separated into silos within the enterprise ecosystem, resulting in fragmented knowledge and inefficiencies in how information is accessed, integrated, and utilized.

The primary objective of this study is to investigate the standardization of unstructured and structured data so that it can be prepared to interact with other systems, specifically with large language models. The viability of these models is contingent upon the accessibility of coherent and contemporary data. In the absence of a standardized data ingestion process, organizations encounter challenges in ensuring data consistency, provenance, and semantic alignment. It is crucial to acknowledge the significance of these elements as indispensable prerequisites for the development of reliable generative artificial intelligence systems.

In the context of the problem space, in addition to the literature review, interviews have been conducted within my company with the responsible persons who are dealing with this problem and aiming to find a solution for it.

Table of Contents

1 Empirical Exploration: Interviews 1

1.1 Objectives and setup 1

1.2 Content analysis of interview 1

2 Theoretical Background 3

2.1 Review of academic research 3

2.2 Review of professional journals 4

3 Problem Statement 5

3.1 Research Question 5

4 Artefact Idea 6

Bibliography 7

List of tools used 8

Appendix A: Interview Guide 1

Appendix B: Interview Transcript – AI Team Lead 3

Appendix C: Interview Transcript – Data Integration Team Lead 35

1 Empirical Exploration: Interviews

1.1 Objectives and setup

The objective of this section was to ascertain the practical relevance and perception of the problems that currently occur within the company. Consequently, the interviews have been conducted with the AI Team Lead and the Data Integration Team Lead to obtain different perspectives and identify relevant pain points. All participants have been informed of the objectives of the interview and have provided consent for the interview to be conducted and for the information to be used in the master's thesis.

1.2 Content analysis of interview

One of the challenges that the company faces is the data integration challenge. This challenge involves the processing of structured data, which consists primarily of public-facing information about companies and other organizations from a multitude of disparate sources. The current data environment within the organization is marked by a significant degree of heterogeneity, necessitating the integration of diverse data exchange formats. These include legacy interfaces (XMLs), REST Application Programming Interfaces (API) (JSON) and other file formats such as Excel/CSV, which persist in their prevalence as a method of data delivery. (D. Mandl, personal communication, November 10, 2025)

In addition to structured sources the organization processes a considerable amount of unstructured data, including annual reports and legal documents in PDF format, The extraction of specific data points from these documents is a prerequisite for their processing. A notable example of unstructured data is represented by PDFs within the company. The process of parsing PDFs has been identified as the most difficult and undesirable ingestion path for the team. (M. Griesmayer, personal communication, November 5, 2025; D. Mandl, personal communication, November 10, 2025) A further challenge arises with semi-structured data such as single field addresses, which require a separation into structured components based on different national standards. (M. Griesmayer, personal communication, November 5, 2025)

Across all data categories, the company identifies poor data quality as one of the most critical issues. A significant proportion of these errors can be attributed to human input, including typos in dates. Such inconsistencies often arise due to the inability of automated systems to effectively reconcile and prevent successful data fusion. Thus, data fusion is often hindered by the presence of contextual and semantic ambiguity. Machines often encounter difficulties in recognizing details that are evident to a human observer. This can result in errors that are challenging to detect or resolve. (D. Mandl, personal communication, November 10, 2025)

The lack of unique common identifiers across heterogeneous sources, in conjunction with the variability of available attributes, poses a significant challenge in facilitating reliable identity fusion or record matching. This arises due to the presence of disparate data elements across sources. For instance, a given source may possess a name and a date of birth, while another source only contains a name and an address, thereby hindering the ability to accurately match records. Therefore, a major operational challenge is the manual effort required for data standardization. The crucial process of determining which fields to adopt and how to align disparate source structures into a unified format is currently driven by manual analysis. (D. Mandl, personal communication, November 10, 2025)

Data vectorization has been demonstrated to be an effective solution for a multitude of issues regarding heterogeneous data. However, the development of a vectorization strategy for structured or unstructured data poses a significant challenge. The method used for unstructured text may not be applicable for structured data. Therefore, it is an essential to investigate a range of vectorization methods tailored to the specific data structure. To address these challenges the team has initiated the use of metadata to identify and categorize data based on its source trustworthiness. The system currently under developing assigns a confidence level to data based on its sources type. Unstructured data has its own challenges, however, structured data within relational database systems, must offer rich metadata and clear column or table naming conventions. This will ensure that large language models (LLMS) can retrieve the correct data in the correct context. (M. Griesmayer, personal communication, November 5, 2025)

Integrated machine learning models often demonstrate superior classification and processing accuracy in comparison to traditional manual coded logic. This suggests that the future of the framework lies in the automation of current manual and programmatic steps using LLM techniques to improve efficiency and results. (D. Mandl, personal communication, November 10, 2025)

Currently the company is using a proprietary tool called Lobster Data Platform, which was originally designed for logistics. This model executes Extract, Transform, Load (ETL) pipelines and perform data format conversion. The conventional data ingestion pipeline follows the ETL process by extracting raw data or files, preprocessing and transforming the data, often converting various input formats including JSON, CSV and XML into a single unified internal XML format. Ultimately, the harmonized data is loaded for the downstream use. (D. Mandl, personal communication, November 10, 2025)

2 Theoretical Background

2.1 Review of academic research

The evolution of data diversity has progressed from a state of simple, structured data to a substantial volume of various forms, thereby hindering the efficient analysis and unification. Data heterogeneity is fundamentally linked to three main data characteristics, the quantity (volume), the multitude of formats (variety) and the speed (velocity). Putrama & Martinek (2024) claim that “similar data from different sources can lead to semantic, structural, and syntactic heterogeneity issues.” Research indicates that 32.6% of integrated data is focused on structured data. Nevertheless, the issue concerning semi-structured and unstructured data have only been addressed by a limited number of researchers. (Putrama & Martinek, 2024)

Further research is necessary to provide comprehensive solutions that unify all data formats including structured, semi-structured and unstructured within a single ingestion framework. The primary challenge for enterprises is the convergence of multi-source, heterogeneous data originating from diverse systems, each featuring various formats and structures. Traditional Extract, Transform, Load (ETL) systems are struggling to meet the demand of real-time data access required for modern business decision making processes. (Putrama & Martinek, 2024)

In recent years, there has been a considerable increase in the potential for unstructured data, as managers are interested in acquiring more insights into user experience and other analytical insights. The fast expansion of unstructured data has created an urgent need for enterprises to adopt a structured approach to the selection and integration of data sources. This is essentially relevant for business intelligence systems or other systems as Retrieval Augmented Generation (RAG) that prepare data for stakeholders. (De Haan et al., 2024)

As currently known, the processing of unstructured data is characterized by its high resource intensity, the necessity of multiple steps, and is inherent uncertainty. Nevertheless, it frequently provides information that structured data alone cannot. For a standardization data ingestion framework, these challenges must be recognized. (De Haan et al., 2024)

As Wang (2017) points out, there are multiple dimensions of data heterogeneity, including differences in syntax and semantics to variations in terminology and differences in interpretation. These factors contribute to the complexity of combining diverse data sources. Moreover, the heterogeneity in big data systems mandates the simultaneous management of structured, semi-structured and unstructured data, specifically associated with the challenges in the data ingestion pipeline. (Wang, 2017)

2.2 Review of professional journals

Conventional data storage methodologies regard data as siloed information. Nonetheless, approximately 68% of enterprise data are not actively utilized. As a consequence, organizations encounter a loss of opportunities, an increase in risk and poor decision-making. Furthermore, numerous companies have developed extensive data repositories over the past ten years. However, a significant portion of this data remains isolated and inactive, resulting in the deterioration of its value rather than strategic advantage. (Sood, M., & Venkatraman, V., 2025)

Despite the capacity of generative AI to process large amounts of enterprise documents, current capabilities still demand extensive human involvement to clean, structure and contextualize unstructured data. The industry has yet to reach where companies can effortlessly “load documents into a prompt” and making standardized ingestion workflows indispensable. A specific insight from this analysis is that leaders must prioritize not only the development of autonomous AI agents, but also the effective management of unstructured data as strategic assets in the year 2025. (Davenpot, T. H. & Bean, R., 2025)

Sood, M. & Venkatraman, V. (2025) are claiming that the issue of data fragmentation has evolved beyond a technical issue, it rather represents a strategic liability, also referred to as “data-debt”, which can potentially be a disadvantage for an organization’s competitive position. In the intelligence era, the key to competitive advantage lies not in amassing data, but in rapidly converting data into valuable insights. Rather than focusing on the sheer volume of data, leading organizations prioritize the analysis of high-velocity data. The implementation of modern data strategy must prioritize the transformation of static, relational databases into dynamic, interconnected intelligence systems. This change is essential for organizations to maintain competitiveness in their respective markets. (Sood, M., & Venkatraman, V., 2025)

3 Problem Statement

In today's business world companies are processing vast amount of data in repositories as database management systems, but a significant part of that data remains inactive and isolated, as there are difficulties in utilizing most of the data, which limits competitive advantage for companies. (Sood, M., & Venkatraman, V., 2025)

The primary pain point to transform these isolated data lies in the complex, inconsistent nature of the data ingestion pipeline. Extreme data heterogeneity in numerous formats of structured data including legacy interfaces, REST APIs and other structured file formats, alongside significant volumes of unstructured data as data formats like PDFs. (M. Griesmayer, personal communication, November 5, 2025; D. Mandl, personal communication, November 10, 2025) Standardizing these diverse sources is complex, marked by different syntax, semantics and terminology. (Putrama & Martinek, 2024) The current process of data standardization is mostly manual and resource intensive. (D. Mandl, personal communication, November 10, 2025) Since data vectorization might be a solution for heterogeneous data, there is a challenge in developing a unified and standardized vectorization strategy that is appropriate for structured and unstructured data. (M. Griesmayer, personal communication, November 5, 2025) In conclusion, the challenge lies in converting fragmented heterogeneous data into valuable information efficiently. On the other hand, manual and ad hoc ingestion processes for different enterprise data prevent companies from realizing the full potential of machine learning systems as RAG in a standardized, automated and hybrid approach.

3.1 Research Question

How can a standardized RAG ingestion framework be designed that leverages AI and machine learning to effectively and efficiently fuse heterogeneous structured and unstructured data, thereby reducing the manual effort and improving the quality and contextual richness of information retrieval?

4 Artefact Idea

The potential artefact of this thesis is the development of a RAG ingestion framework that addresses challenges from heterogeneous enterprise data. The framework will define design principles for the preparation, standardization, and fusion of structured and unstructured sources. It introduces a standardized approach for chunking data into semantically coherent units (vectors) and outlines a RAG architecture that integrates data into a semantic layer to provide large language models with contextually rich information. Together, these components enable consistent data ingestion flows and improve reliability, interpretability, and utility.

Bibliography

Davenpot, T. H. & Bean, R. (2025, January 8). Five Trends in AI and Data Science for 2025 From MIT Sloan Management Review. *MIT Sloan Management Review (via PR Newswire)*. https://www.prnewswire.com/news-releases/five-trends-in-ai-and-data-science-for-2025-from-mit-sloan-management-review-302345115.html

De Haan, E., Padigar, M., El Kihal, S., Kübler, R., & Wieringa, J. E. (2024). Unstructured data research in business: Toward a structured approach. *Journal of Business Research*, *177*, 114655. https://doi.org/10.1016/j.jbusres.2024.114655

Griesmayer, M. (2025, November 5). *Interview Teamlead AI* [Interview].

Mandl, D. (2025, November 10). *Interview Teamlead Data Integration* [Interview].

Putrama, I. M., & Martinek, P. (2024). Heterogeneous data integration: Challenges and opportunities. *Data in Brief*, *56*, 110853. https://doi.org/10.1016/j.dib.2024.110853

Sood, M., & Venkatraman, V. (2025, September 2). Is Your Enterprise Data Strategy Ready for the Age of Intelligence? *Harvard Business Review*. https://hbr.org/sponsored/2025/09/is-your-enterprise-data-strategy-ready-for-the-age-of-intelligence

Wang, L. (2017). Heterogeneous Data and Big Data Analytics. *Automatic Control and Information Sciences*, *3*(1), 8–15. https://doi.org/10.12691/acis-3-1-3

List of tools used

AI tool	Purpose	Concerned parts of the work	Notes
Deepl Translater https://www.deepl.com/de/translator	Translation of text passages	Whole document	
Deepl Writer https://www.deepl.com/de/translator	Rephrase and grammar check	Whole document	
Chat GPT http://chatgpt.com/	Creating an interview guide	Interview guide	Drafting the specific interview questions for the problem space
Chat GPT http://chatgpt.com/	Researching literature sources	Theoretical background	Researching literature accessible via the library catalogue.
Gemini http://gemini.google.com/	Brainstorming and understanding the problem	Problem Space	Building the knowledge foundation for this topic
Gemini http://gemini.google.com/	Content analysis of interviews	Interviews	Support with the content analysis of the interview transcripts

Appendix A: Interview Guide

Interviewleitfaden – Masterarbeit

Thema: RAG Ingestion Framework: Standardizing the Fusion of Heterogeneous Structured and Unstructured Enterprise Data

Einleitung

Vielen Dank, dass du dir Zeit für dieses Interview nimmst. Im Rahmen meiner Masterarbeit untersuche ich, wie Unternehmen strukturierte und unstrukturierte Daten verarbeiten, integrieren und für KI-Anwendungen insbesondere Retrieval-Augmented Generation (RAG) nutzbar machen können. Ziel der Interviews ist es, praktische Einblicke in bestehende Prozesse, Herausforderungen und Lösungsansätze zu gewinnen. Die Gespräche dauern ca. 30–45 Minuten und dienen ausschließlich Forschungszwecken. Deine Perspektive hilft dabei, Anforderungen, Engpässe und Potenziale für ein standardisiertes RAG-Ingestion-Framework besser zu verstehen.

A. Einstieg

- Kannst du kurz deine Rolle im Unternehmen beschreiben und was du im Bereich Daten bzw. KI machst?
- Welche Bedeutung haben Generative-AI-Anwendungen (z. B. RAG, Chatbots, Assistants) aktuell für dich bzw. dein Team?
- Wie würdest du die aktuelle Datenlandschaft im Unternehmen grob beschreiben? (z. B. Datenquellen, Schnittstellen, Systeme)

B. Datenintegration & Data Ingestion – Data Integration Team

- Welche Systeme und Technologien nutzt ihr zur Verarbeitung und Integration strukturierter Daten?
- Wie läuft bei euch ein Data-Ingestion-Prozess ab, von der Quelle bis zur Nutzung?
- Welche Herausforderungen treten beim Zusammenführen und Standardisieren unterschiedlicher Datenquellen am häufigsten auf?
- Welche Rolle spielen Datenqualität, unterschiedliche Modelle/Schemas oder kulturelle Unterschiede (z. B. Namen)?
- Welche Standards, Tools oder Frameworks nutzt ihr aktuell (z. B. ETL-Strecken, Mapping, Lobster, Apache NiFi)?
- Was bräuchte es aus deiner Sicht, um strukturierte Daten besser zu standardisieren und für KI-Systeme nutzbar zu machen?

B. Datenintegration & Data Ingestion – AI Team

- Welche Erfahrungen hast du bisher mit RAG oder ähnlichen Frameworks gesammelt?
- Welche Daten nutzt ihr aktuell für KI-Modelle oder Prototypen? (Quelle, Struktur, Formate)
- Wo liegen dabei die größten Herausforderungen, besonders bei unstrukturierten Daten wie PDFs, OCR etc.?
- Wie geht ihr heute mit der Aufbereitung von Daten um (z. B. Embeddings, Vektordatenbanken)?
- Welche Probleme entstehen durch uneinheitliche oder schlecht verknüpfte Datenquellen?
- Welche Anforderungen müsste eine standardisierte RAG-Ingestion-Pipeline erfüllen, damit sie eure Arbeit sinnvoll unterstützt?

C. Zusammenarbeit & Organisation

- Welche Teams oder Rollen sind aktuell in den Data-Ingestion-Prozess eingebunden?
- Wo gibt es organisatorische oder kommunikative Hürden zwischen Data-Integration und AI-Team?
- Welche Schnittstellen oder Tools würdest du dir wünschen, um Daten effizienter zwischen Teams bereitzustellen?
- Wie sollte eine ideale Zusammenarbeit aussehen, um RAG-Projekte besser zu unterstützen?

D. Ausblick & Anforderungen

- Wie wird sich die Datenlandschaft deiner Einschätzung nach in den nächsten 2–3 Jahren entwickeln, insbesondere im Hinblick auf Generative AI?
- Welche Eigenschaften müsste ein RAG-Ingestion-Framework haben, um echten Mehrwert zu bieten (z. B. Automatisierung, Transparenz, Governance, Wiederverwendbarkeit)?
- Welche Risiken oder Stolpersteine siehst du bei der Einführung einer solchen Standardisierung?

Appendix B: Interview Transcript – AI Team Lead

Interview AI Teamlead – Max Griesmayer 6. November 2025, 12:02PM

42 Min. 33 Sek.

Patrick Roith
Passt ich glaub, du musst irgendwas auch bestätigen, oder die Kamera musst du und den Ton musst du wieder einschalten ich glaub das.
Ist bei Teams immer so? Ja, jetzt geht es perfekt.

Max Griesmayer
Tritt.
Genau mit der Hinweis, dass das jetzt aufgenommen wird.

Patrick Roith
Ah super, denn erstmals vielen vielen Dank, dass du dir überhaupt die Zeit nimmst, auch für für meine Masterarbeit oder für das Thema auch generell. Wir haben eh schon mal kurz darüber gesprochen, vor ein paar Wochen, glaube ich ist das schon her genau und es geht im Endeffekt eigentlich darum, dass man ein bisschen praxiseinblicke bekommt auch Problemstellungen.
Verbesserungsmöglichkeiten auch deine Rolle mal im Unternehmen ein bisschen näher erläutert noch für die Masterarbeit und ich will auch gleich mal damit beginnen, als das Thema für die Masterarbeit, die ich jetzt mal einfach so hab ist Reg Inchestion Framework und da geht es im Endeffekt darum die Standardisierung.
Von heterogenen Datenquellen, sprich strukturierten und unstrukturierten Unternehmensdaten und da eben einen einen Standard eben zu finden ja, und diese Daten eben dann sowohl die unstrukturierten, also auch die strukturierten Daten so aufzubereiten durch Vektorisierung. Das haben wir auch, glaub ich letztes Mal kurz besprochen.

Max Griesmayer
Mhm.

Patrick Roith
Um sie eben für generative AI et cetera für LL MS verwenden zu können mittels Track genau und da du eben der beste Ansprechpartner, wer das bist, freue ich mich umso mehr, dass du dir auch die Zeit genommen hast genau und ich würde mal, du kannst jederzeit irgendwelche Fragen allgemein.

Max Griesmayer
Ja.

Patrick Roith
Natürlich stellen aber ich würde mal einfach generell die die Fragen nicht vorbereitet hab mal einfach kurz durchgehen und voll genau also zum Anfang mal vielleicht kannst du ganz kurz deine Rolle im Unternehmen nur kurz sagen was du machst und was so dein Bereich ist im Unternehmen.

Max Griesmayer
Passt.
Genau also ich bin im Unternehmen der Lead vom EI Team und wir kümmern uns um alle Implementationen rund um das Thema EI, beginnend von von Machine Learning zu bisschen auch Datenanalysen bis hinzu Produkten um.
Vor allem unsere Daten aufzubereiten, nach außen hin EI Funktionen zur Verfügung stellen, aber auch intern bisschen das wieder Thema, was jetzt, was jetzt eventuell nächstes Jahr wieder mehr wird.

Patrick Roith
Mhm.

Max Griesmayer
Zu befähigen, mit mit unterschiedlichen Tools und mit dem Umgang mit den den Dingen, die es schon gibt, da draußen.

Patrick Roith
Mhm so ganz allgemein gesprochen wie wie siehst du die Relevanz von generative AI wie auch Reg zum Beispiel Chat Botsets im Unternehmen auch ein bisschen im Hinblick auf den Wirtschaftskompass et cetera für intern versus extern auch zum Beispiel, wenn man so vergleichen würde.

Max Griesmayer
Genau es gab generell also dieses der Hype ist nicht umsonst da, den den die generative KI jetzt noch mal mitgebracht hat, wo es davor schon mit den klassischen Noden, sag ich mal eine gewisse Art von Hype da war, aber das da mal andere Ausmaße genommen.

Patrick Roith
Mhm.

Max Griesmayer
Hat das schon auch an?
Eine neue Leichtigkeit im Sinne davon, dass man nicht nur eigene Modelle trainieren muss, sondern eben riesige Modelle nutzen kann extern beziehen kann, einbinden kann, um relativ

schnell unterschiedliche Lösungen.
Zu zu erstellen.

Patrick Roith
Mhm.

Max Griesmayer
Beziehungsweise auch um das tägliche Doing von uns allen ich glaub das geht quer über alle Branchen an der einen anderen Stelle zu zu erleichtern, effizienter zu gestalten, zu unterstützen.

Patrick Roith
Mhm siehst du da, weil du das gerade angesprochen hast, siehst du dir die Relevanz bei internen Verbesserungsmöglichkeiten höher als bei externen, also externen mein ich jetzt so User Focus und intern mein ich jetzt für Mitarbeiter genau.

Max Griesmayer
Genau.
Genau intern ist es immer leichter, weil.
Da unterstütze ich Leute, die jetzt nicht unbedingt dafür bezahlen. Extern ist es dann immer.

Patrick Roith
Mhm.
Ja.

Max Griesmayer
Meistens der Teil eines Produkts in der einen oder anderen Form und da müssen natürlich viel mehr Überlegungen dahinter stehen. Da muss es viel stabiler sch e viel robuster die Ergebnisse kommen, weil ja doch eine gewisse Erwartungshaltung von außen da ist und das.

Patrick Roith
Mhm.

Max Griesmayer
Wenn schlecht umgesetzt ist, auch ein Schaden anrichten kann im schlimmsten Fall also. Da sehe ich dann schon noch mal die Unterschiede in dem Ganzen.

Patrick Roith
Ja.

Max Griesmayer
Thema Governance wie wie geht man mit solchen Lösungen um? Ja.

Patrick Roith
Mhm.
Ja OK also governance ist auch prinzipiell so eine eine eine Challenge oder ein ein Thema, das das ganz stark wahrscheinlich auch ist im externen Bereich Schützig, oder?

Max Griesmayer
Genau das ganze Thema Monitoring, Governance, Güte geben, das ist was bei bei klassischen was nennt die was klassisches Machine Learning kann? Ich kann ich.

Patrick Roith
Ja.
Mhm.
Ja.

Max Griesmayer
Gewisse Güte bestimmen und sagen OK mit der und der Genauigkeit kann ich dieses und jenes Problem oder diese Klasse von anderen unterscheiden also ich sag mal diesen generativen KI, die generiert mir immer was schwer messbar zu machen.

Patrick Roith
Mhm.
Mhm ja.

Max Griesmayer
Weil die meisten Modelle auch dann nicht.
Konsistent sind im Sinne von wenn ich zehnmal den gleichen Input geb, dass ich zehnmal den gleichen Output Krieg, sondern ich kann eigentlich das bisschen einschränken, aber oft dann auch nicht zu 100% sagen, dass dann ja immer das gleiche Ergebnis rauskommt.

Patrick Roith
Ja toll, Mhm OK, wie würdest du auch mal sehr, sehr allgemein gesprochen? Im Überblick wie würdest du so die Datenlandschaft im Unternehmen, sprich auch eigentlich in deinem Bereich oder mit deinen Berührungspunkten so beschreiben? Was sind so die Schnittstellen, die die Tools, Datenbanken et cetera?

Max Griesmayer
Genau.

Patrick Roith
Konstrukturierte Form, unstrukturierte Form, mit denen ihr euch eigentlich gerade im Team beschäftigt und vielleicht kannst du auch da kurz sagen so was sind so die die Pain Points, die die wichtigsten Schnittstellen et cetera mal kurz im Überblick.
Gesprochen.

Max Griesmayer
Ja, also prinzipiell unser Unternehmen lebt von Daten, das heißt, Wir beziehen Daten, verarbeiten Daten und und verkaufen im Endeffekt dann auch diese Daten. Das ist unser Kerngeschäft und da gibt's natürlich alle möglichen Formate. Also es gibt Daten.
Quellen, wo Daten strukturiert herkommen, gibt doch auch sehr viel Datenquellen, wo wir unstrukturierte Daten haben, wo es PDF Geschäftsberichte sind, wo es Urkunden sind, wo es alles Mögliche an an unterschiedlichen Dokumenten sind, aus denen Daten extrahiert werden müssen.

Patrick Roith
Mhm.
Mhm.

Max Griesmayer
Was teilweise, wenn es klar Informatik geht, automatisiert gut funktioniert und auf anderen Ecken und Enden fiel noch manuell da redaktionell.
Rausgezogen wird, wo natürlich jetzt so eine generative KI ein ein Modell, das das PDFS das Bilder versteht, das vielleicht dann bisschen ein schlecht gescannten OCR besser versteht, dann wieder helfen kann.

Patrick Roith
Mhm.
Ja OK wie sieht's mit anderen Schnittstellen aus also du hast jetzt auch eben sehr unstrukturierte Datenquellen angesprochen mit PDFS et cetera und wie sieht's da mit mit strukturierten Schnittstellen aus, also Abis, zum Beispiel et cetera ist das für euch aktuell ein Thema oder ist das eher?
Weniger.

Max Griesmayer
Genau bei uns ist es, wir stehen oft dazwischen zum Teil, das heißt, wir haben Workflows, auch was strukturierte Daten herkommen und zum Teil auch teilstrukturierte Daten. Da ist klar jetzt kommt eine Adresse und die Adresse für sich ist dann immer eine vollständige Adresse aber.

Patrick Roith
Mhm.
Mhm.

Max Griesmayer
Da geht's dann drum, die Adresse Aufzubröseln in OK was ist eine Stadt, was ein Land, was ist eine Postleitzahl, was gehört zu zu einem Haus dazu? Was sind jetzt andere zahlen? Das unterscheidet sich von Land zu Land, und das würde ich jetzt mal als Semi strukturiert bezeichnen.

Patrick Roith
Mhm.
Mhm ja.

Max Griesmayer
Ja, weil es zwar ein Feld der Datenbank ist, aber eigentlich.
Könnte das aufgeteilte mehrere Felder und aber sonst auch?
Gerade zum Trainieren gibt es andere Use Case, wo man wirklich aus der Datenbank strukturiert Felder Felder beziehen.

Patrick Roith
Mhm.

Max Griesmayer
Aber sehr oft ist es dann auch wieder Text, das heißt, wir haben dann in einer Tabelle Namen Adressen, wie ich schon gesagt hab Bezeichnungen die.

Patrick Roith
Ja, hm.

Max Griesmayer
Ja.

Patrick Roith
OK, Mhm passt vielleicht auch jetzt noch mal kurz zu zu RAG um, um zu RAG zurückzukommen Frameworks et cetera welche welche Erfahrungen habt ihr bis jetzt mit RAG gesammelt? So auch Überblicksmäßig im Unternehmen in einem Bereich oder vielleicht auch schon davor vom.

Max Griesmayer
Ja.

Patrick Roith
Vom vor deinem deinem jetzigen Job und welche ähnlichen Frameworks was sind so vielleicht auch zusammengefasst für dich so die wichtigsten Vorteile Pain Points vielleicht auch Probleme ja kurz mal so in einem Überblick.

Max Griesmayer
Genau also prinzipiell habe ich davor, beim bei meiner Station davor, da war ich eben für generative KI bei einem Beratungsunternehmen für den deutschsprachigen Markt im öffentlichen Sektor zuständig und da haben wir einige Reg Anwendungen gebaut, wo es zum einen Drum ging, dass man.

Patrick Roith
Mhm.

Max Griesmayer
Die man ermöglicht, ihre eigenen Daten durch super zu machen aber.

Patrick Roith
Mhm.

Max Griesmayer
Das sind an vielen verschiedenen Spezifikationen also da ging es dann drum die einen wollten eher, dass man etwas Ray rausfindet, ob man Duplikate findet, Dokumenten, die anderen wollten wie gesagt ja, so ihr Wiki befragbar machen. Wie haben es intern jetzt gerade so ein PUC, wo man?

Patrick Roith
Mhm.

Max Griesmayer
Ja, das Wiki, also unsere unser Wiki, die Daten beziehen und da mal mit einem Rack versuchen was zu bauen, dass man in dem Open Source Wikis wir verwenden und doch Inhalte auffindbar machen kann.

Patrick Roith
Mhm.
Mhm OK, ja, cool, vielleicht auch jetzt, weil wir über Ray gesprochen haben, noch mal kurz zurück zu den Daten jetzt hab ich schon oder haben wir schon kurz angeschnitten, dass eben sehr viel mit strukturierten, unstrukturierten Daten.

Max Griesmayer
Ja.

Patrick Roith
Gearbeitet wird, es wird mit Datenbanken gearbeitet. Es wird eben auch jetzt zum Beispiel, wenn in einer strukturierten Datenbank mehr oder weniger textfelder sind. Ist das auch wieder ein Text Format, kann man sagen was sind so da für für euch, die die größten Herausforderungen, oder?
Hürden sag ich mal, um diese Daten zu fusionieren, also diese heterogene datenlandschaft, sag ich mal zwischen strukturiert und unstrukturiert was ist, was sind so eure größten Probleme? Themen um das zu standardisierten?
Standardisieren, fusionieren et cetera.

Max Griesmayer
Genau da haben wir derzeit noch eigentlich noch keinen Use Case, wo, wo wir das so benötigen, also wir das Use Case, wo wir das eine verwenden. Use Case muss andere verwenden, aber noch nicht, dass man sagt, man kommt jetzt von diesem unstrukturierten Wiki zum Beispiel.

Patrick Roith
Mhm.
Mhm.

Max Griesmayer
Auch zusätzliche Informationen aus einer strukturierten Datenbank, um das zu verschmelzen.

Patrick Roith
Mhm.

Max Griesmayer
Wo es, glaube ich schon Use Cases gibt irgendwo in einem Backclock wo wo das Mal schlagen werden könnt. Das machen wir aber im Moment noch nicht aktiv.

Patrick Roith
Ja.
OK, könntest du dir aber vorstellen jetzt grundsätzlich was du die die Probleme sein könnten, wenn man das fusioniert also jetzt auch ohne Use Case was sind so die die größten Hürden, um das zu fusionieren verschiedene Datenstrukturen?

Max Griesmayer
Ja, prinzipiell glaube ich.
Liegt es dann einmal vor allem daran, wie ich das jetzt?
Wer also aus den strukturierten und strukturierten Beziehungen aufbauen kann?

Patrick Roith
Mhm ja.

Max Griesmayer
Das wird zum Teil möglich sein über IDS weil ich weiß keine Ahnung. Dem Kunden ist es Dokument zugeordnet und aus dem Dokument könnte ich jetzt dann diese Beziehung herstellen?

Patrick Roith
Mhm.
Mhm.

Max Griesmayer
Ah.
Das ist wahrscheinlich ein Thema, wie man, wie man diese Beziehungen aufbaut, weil ich glaube, auch da könnte dann wieder eine generative KI eventuell gute Arbeit leisten.

Patrick Roith
Mhm.
Mhm.

Max Griesmayer
Dann ist es so, dass man, glaub ich oft.
Pipelines hat, wo man die KI dann entscheiden lässt. Hole dir jetzt Daten aus einer strukturierten Datenbank oder einer unstrukturierten. Ich glaube, bei uns ist das Thema soll es die Datenbanken sehr groß sein. Das heißt die die Anwendung müsst sehr viel wissen Datenbank, um dann die richtigen Tabellen und Beziehungen.

Patrick Roith
Mhm.

Max Griesmayer
Herzustellen und daraus zu beziehen es gibt ja unzählige Tabellen und noch mal mehr Views, die darauf aufbauen. Das heißt, das wäre schon eine Herausforderung.

Patrick Roith
Ja.
Mhm.
Mhm.

Max Griesmayer
Wie man das dann so zur Verfügung stellen könnte, dass sich jetzt ein LM beispielsweise automatisieren mit Select Statements also die Daten holen könnte und dann aus einem unstrukturierten RAG was holen könnte, um dann zu vermischen?

Patrick Roith
Mhm.
Mhm, OK ist da ist da aktuell bei euch gerade ein Thema auch dass ihr Daten vektorisiert oder ist das bei euch noch nicht aktuell so?

Max Griesmayer
Ja.
Genau wir haben derzeit eigentlich nur diesen POC, für die das interne Wiki, wo Daten vektorisiert werden.

Patrick Roith
Mhm.

Max Griesmayer
Und dann noch also es gibt also, wenn auch Geschäftsberichte, die wir also haben, lange Dokumente, aus denen wir einzelne Felder extrahieren wollen und da verwenden wir auch schon wollen wir verwenden. Das ist alles noch in der.

Patrick Roith
Mhm.

Max Griesmayer
Bei einer Entwicklungsphase, einer sehr anfänglichen, dass man lange Dokumente vektorisiert und dann doch aber einen großen Teil wegwirft und sich nur die Absätze behält, wo man davon ausgeht, dass.

Patrick Roith
Mhm.
Hm.

Max Griesmayer
Dass dieser Inhalt, den man extrahieren möchte, ab vorkommen.

Patrick Roith
OK und?

Max Griesmayer
Sogar so eine minirag Pipeline für ein einzelnes Dokument, das sehr lang ist, wo man dann viel wegwirft und sagt Gib mir nur die, die die Top 5.

Patrick Roith
Mhm, Mhm.
OK, Mhm und wo du gesagt hast ein ein definitiver Paint Point oder eine Herausforderung im Endeffekt ist auch diese diese Beziehungen zu schaffen, jetzt nicht nur zwischen unstrukturierten und strukturierten Daten, sondern auch wahrscheinlich. Generell wäre das auch dann.

Max Griesmayer
Ja.

Patrick Roith
Lösbar mit der Vektorisierung von Daten also kann man bei dieser Beziehung Thematik oder Problematik lösen?

Max Griesmayer
Schwierig glaub ich also da hab ich jetzt ad hoc auch keine keinen keinen Ansatz.

Patrick Roith
Mhm.
Ja. KK.

Max Griesmayer
Ja.

Patrick Roith
Passt OK, passt passt genau, dann haben wir jetzt muss ich noch kurz nachschauen. Genau also Vektorisierung, hast du gesagt, ist auf jeden Fall beim PUC einfach ein Thema jetzt aktuell und ist wahrscheinlich auch in der Zukunft ein ein Thema, wenn sie einen passenden Use Case dafür habt wahrscheinlich oder schätze ich mal.

Max Griesmayer
Genau also überall, wo es darum geht, dass man das eine große Menge an unstrukturierten Daten.

Patrick Roith
Mhm.

Max Griesmayer
Eine kleine Menge Rauszieht sage ich einmal oder die ein bisschen filtern möchte und dann dann ist eine Vektorisierung mit.

Patrick Roith
Mhm.

Max Griesmayer
Mit großen empedding Modellen immer ein guter Weg und das haben eben diese ganzen rec use cases. Da gibt es jetzt auch gezeigt, dass das durchaus einen Mehrwert hat, dass man nicht alle Daten verarbeiten muss, sondern billigeren Schritten. Nenn ich einmal einen günstigeren Schritt davor setzt?

Patrick Roith
Ja OK.
Ja.
Ja.

Max Griesmayer
Oh Mann, ja.

Patrick Roith
OK das das kommt, da komme ich auch gleich dann zur nächsten Frage welche Anforderungen meinst du müsste man oder müsste es müsste eine standardisierte Reg intestion Pipeline haben, um generelle LLMS oder generative AI wirklich nutzbar zu machen? Also was wie müsste die Vorbereitung?
Auch der Daten generell sein, um das wirklich zu standardisieren und für Ray gut nutzbar zu machen. Was wäre da so der?

Max Griesmayer
Ja mehr Punkte, die immer ganz wichtig sind, sind beginnend also ich les mal das Dokument ein, da geht mal schon aus, dass man schon schön digitalisiert hat. Da ist der erste Schritt dann oft wie digitalisiert man das überhaupt? Aber wenn man das hat ist gerade wenn man vom Text spricht und von Dokumenten die Frage wie.

Patrick Roith
Hallo.
Mhm.
Ja.

Max Griesmayer
Chunkt man das also, wie kleinteilig oder großteilig Splittich so ein Dokument oder so ein Text und wieviel Überlappungen habe ich?

Patrick Roith
Mhm.
Mhm.

Max Griesmayer
Das kann kann zur Güte beitragen. Das sollte dann vermutlich auch relativ konsistent sein, wobei man auch da überlegen kann, ob man halt manche daten bisschen bisschen weniger macht, manche mehr.

Patrick Roith
Mhm.
Mhm.
Mhm.

Max Griesmayer
Die Wahl wahrscheinlich vom vom vom Modell, das man zum Erstellen dieser Sektoren wählt.

Patrick Roith
Mhm.

Max Griesmayer
Wenn man, wenn man jetzt also man unterscheidet ja auch zwischen einer semantischen Vektorisierung und.
Das zweite fällt mir jetzt nicht ein.

Patrick Roith
Macht nix.

Max Griesmayer
Genau es gibt auch unterschiedliche Methoden dann wie man, wie man so ein Vektor, wenn man so ein Vektor stellt, ob man dann wirklich den den Inhalt versucht dann semantisch

wiederzugeben, das was was JGBT gut macht, was diese Modelle gut können oder ob ich sage, eine klassische Suche mit Zeichen hab.

Patrick Roith
Mhm.
Mhm ja.
Ja ja.
Mhm.

Max Griesmayer
Und auch da könnte wahrscheinlich beides dann wieder in einer Kombination sinnvoll sein, aber auch in einzeln.

Patrick Roith
Mhm OK das bezieht sich aber auf die Datenqualität jetzt eher oder auf auf die auf den Kontext.

Max Griesmayer
Ah.
Ich glaub, das ist genau das Vorbereiten vom von dieser von dieser Vektordatenbank das heißt.

Patrick Roith
Mhm.

Max Griesmayer
In dieser in dieser Vorbearbeitung wie wie ich meine meine Knowledge Base aufbauen möchte, gibt's unterschiedliche unterschiedliche Schritte, die man, die man.

Patrick Roith
Mhm.
Mhm.

Max Griesmayer
Mitbedenken kann oder sollte.

Patrick Roith
Okay.
Ja, dann vielleicht die, die die nächste Frage, die ich hätte was sind so die die wichtigsten Themen, die dir einfallen oder die du auch erfahren hast in Deiner in deiner Erfahrung bezüglich eben Datenqualität und auch Kontextkonsistenz zum Beispiel.

Auch Tracability zum Beispiel ist auch immer ein Faktor, wenn man, gerade wenn man mittels RAG einfach Daten in LLLM spielt, mehr oder weniger, dann ist das nachvollziehbar et cetera, sie gibt's da was sind so da die die wichtigsten Themen, die irgendwie auf die man achten sollte, die man bedenken sollte?

Max Griesmayer
Genau Thema, Kontext also Kontext ist ist Key irgendwo bei diesen LEMS, das heißt und da unterscheiden sich dann ja auch wieder die einzelnen Modelle von den unterschiedlichen Anbietern ein wenig, wieviel Kontext, dann wieder zu viel ist und wieviel dann zu wenig ist.

Patrick Roith
Mhm.
Mhm, Mhm.

Max Griesmayer
Natürlich auch abhängig, dann immer von dem.
Ah.
Von dem, von dem Out Out System prompt den man dann mitgibt, aber prinzipiell glaube ich.

Patrick Roith
Mhm.

Max Griesmayer
Sollte man schon mal schauen, dass der Kontext bei einer gleichen Frage immer der gleiche ist und wie wie kriege ich den besten Kontext? Und auch da gibt es wieder unterschiedliche.

Patrick Roith
Hm.

Max Griesmayer
Methoden wie man dann entscheiden kann, ob man die Frage oder dieses Retriever.

Patrick Roith
Mhm.

Max Griesmayer
Also wenn man davon ausgeht, dass der User eine Frage stellt, die beantwortet haben möchte, ob man die 1 zu 1 weitergibt oder ob man im Zwischenschritt aus dieser Frage noch mal mehrere andere Fragen erzeugt und dann?

Patrick Roith
Ja.
Mhm.

Max Griesmayer
Da mehr mehr Inhalt zu bekommen und den dann noch mal in einem Schritt danach ein zweites Mal zu filtern zu re ranken und dann die möglichst besten Inhalte, sag ich einmal.

Patrick Roith
Mhm.
Okay.
OK und ja, und der und der Punkt Gracability ist Nachvollziehbarkeit ist ist das ein Thema oder ist das?

Max Griesmayer
An Ellen hinzugeben.
Genau das ist gerade wenn man gleich Richtung produktive, also produktive Systeme denkt und.

Patrick Roith
Mhm.

Max Griesmayer
Systeme nach außen ist es ein großes Thema, wo man was unterschiedliche Produkte aber gibt, die das, die das ganz gut machen, die das dann auch auf der Box dann mitchecken, wo man jeden Schritt sieht was passiert eigentlich? Welche Texte werden geholt?

Patrick Roith
Hm.

Max Griesmayer
Wieviel docken werden verbraucht, wie schnell dauert, wie langsam, was kommen für Antworten, was kommt am Ende raus?

Patrick Roith
Hm.

Max Griesmayer
Das super wichtig ist um.
Zum Testen, zum Validieren und auch eben zum zum Monitoren.

Patrick Roith
Ja, Mhm.

Max Griesmayer
Wo es aber dann auch wieder gerade Richtung, also das wirklich produktive System.
Muss man sich auch anschauen, wieviel man da mittracken darf, weil es dann oft wieder um um heiklere Daten geht, wo man dann gar nicht im im Plaintext welche Anfragen haben möchte, aber auch da gibt's Lösungen.

Patrick Roith
Danke.
Dann.
OK, vielleicht noch mal ein bisschen allgemeiner gesprochen wo wo siehst du das? Das größte Potenzial von Reg sag ich jetzt mal, oder auch ein bisschen zur Vektorisierung von von Daten Bezug, vielleicht auf Automatisierung oder auch auf Effizienzsteigerung, zum Beispiel, so Stichwörter.

Max Griesmayer
Mhm.
Genau ich glaub das Reg.
Ist ja deshalb so so gut, wenn man eben keine Modelle neu trainieren muss, sondern on the Fly. Das Wissen mit dem Modell mitgibt und sagt das ist jetzt das, was du was du weißt und daraus bauen wir jetzt eine Antwort oder extrahier mir was oder wie auch immer.

Patrick Roith
Mhm.
Mhm.
Mhm.

Max Griesmayer
Und das ist bei allen Use Cases, wo ich viele Daten habe, wo ich aus einem großen Topf an Daten eine kleine Menge rausschneiden möchte, dann.
Und vor allem an an textualisierten Daten sag ich einmal ist es gibt, ist es ein ein Weg, um um recht schnell schöne an Mehrwert zu generieren, Antworten zu generieren, Dinge zu extrahieren.

Patrick Roith
Mhm.

Max Griesmayer
Vorzufiltern.

Patrick Roith
Ja.

Max Griesmayer
Genau und ich glaub, das sind dann auch wieder die Themen, wo es wo es viele Daten gibt, also wo ich jetzt klassisch man denkt wirklich einen Chatbot, wo man jetzt eben seine eigene Dokumentation befragen möchte oder wo ich jetzt einen Kunden hab, der vielleicht.

Patrick Roith
Mhm.

Max Griesmayer
Supportthemen hat, das ist der ganze Chat Support auf einer Homepage, wo ich sag OK das das funktioniert nicht, dann kann man sich im Hintergrund dieses Ding anhand von Problemen dann die Antworten suchen, die es vielleicht schon niedergeschrieben gibt oder aus dem Handbuch, um dann Antworten zu geben.

Patrick Roith
Hm.
Mhm.
Mhm.
OK ja, wenn du jetzt noch mal kurz vergleichst. Diese 2 Themenbereiche mit so ich sag es mal allgemein Daten, Vorbereitung, Aufbereitung für Reg und dann noch mal Reg mit LM et cetera wo siehst du von den beiden Bereichen? Wieso die?

Max Griesmayer
Mhm.

Patrick Roith
Größeren Herausforderungen, größeren Probleme, größeren Themen, die nicht so einfach sind, weil Reg löst ja auch immer dieses Problem, dass einfach Daten sehr tagesaktuell dann eben sind und eben KI, Systeme et cetera oder generative ideal sehr aktuell.
Sein kann und mit frischen Daten befüllt werden kann. Wusstest du da irgendwie den die größeren Herausforderungen die größeren Probleme oder Hürden in den beiden Bereichen?

Max Griesmayer
Also es kommt auf den Kontext drauf an, auch ein bisschen, aber oft ein Problem ist es, dass

die zugrundeliegenden Daten einfach nicht nicht sauber sind. Das heißt, ich will auf ganz viel in so einen Weg rein, also so.

Patrick Roith
Mhm.

Max Griesmayer
Also meine also meine Knowledge Base und hab dann duplikate hab vielleicht Inkonsistenzen, weil ich meine ganzen internen Dokus irgendwie powerpoints reinwerf und dann gibt es aber dreimal das gleiche powerpoint wo viel mal was anderes drinsteht.

Patrick Roith
Ja.
Mhm.
Mhm.

Max Griesmayer
Das ist wieso oft ist es die Datenbasse, die Stimmen muss.

Patrick Roith
Mhm.

Max Griesmayer
Ähm.
Und wenn das sauber ist, also ich glaub, das war das größte Problem ist es auch so, dass gerade in der Verarbeitung, wenn ich sehr viele Daten habe, ist es auch kostspielig und auch da muss man aufpassen je besser man vektorisierung sein soll, also man im Wedding, desto größere Modelle brauche ich, desto rechenintensiver beziehungsweise.

Patrick Roith
Mhm.
Mhm.

Max Griesmayer
Teurer werden sie im Einkauf.

Patrick Roith
Ja, Mhm.

Max Griesmayer
Ähm.

Patrick Roith
Tja.

Max Griesmayer
Und dann hat man eben den ganzen Punkt des des Retrievels. Das heißt welche welche Informationen bekomme ich zurück?

Patrick Roith
Hm.

Max Griesmayer
Dass das funktioniert dann gleich meistens recht gut. Ich glaub, da sind die Challenges wahrscheinlich auch da, aber dann abhängig vom Problem dann vielleicht nicht ganz so groß.

Patrick Roith
Mhm.
Okay.

Max Griesmayer
Und dann hab ich die dann die Erstellung hinten raus, er ist dann wieder bisschen Spielerei und hängt dann ganz stark von den anderen Themen ab, zusätzlich zu dem zu dem zu dem prompt den man dann dann dazu gibt.

Patrick Roith
Mhm, OK.

Max Griesmayer
Ja, aber dann auch im Embedding ist jetzt so oder in meiner Vektorisierung vektorisiere ich halt wirklich nur einzelne Absätze oder sage ich.

Patrick Roith
Ja.
Mhm.

Max Griesmayer
Oder ich beginne schon mal wie wie mache ich es, mache ich Absätze oder sage ich 200 Wörter circut oder versuche ich es irgendwie seitenweise zu machen und da gibt es dann auch wieder Methoden das was hierarchisch aufbaut also ich habe mal.

Patrick Roith
Ja.

Max Griesmayer
Ich mach pro Kapitel 1 und ich hab im Kapitel noch mal pro pro Subkapitel und dann noch mal pro Absatz und hab quasi so einen so einen Baum an an Indizes auch Daische Use Cases gesehen, wo sich das dann da der der Ansatz sehr bewährt.

Patrick Roith
Mhm.
Mhm.

Max Griesmayer
Genau und ja.

Patrick Roith
OK, weil du das das ist, das ist ein super Thema, was du gerade gerade ansprichst, weil ja auch mein mein Master Thema aktuell so ist, dass ich es eben versuche zu standardisieren, eben diesen Prozess oder diesen Framework mit der Vorbereitung, also Data Injession.

Max Griesmayer
Mhm.

Patrick Roith
Würdest du denn eigentlich sagen jetzt vielleicht, weil du das eben jetzt so erwähnt hast, dass es vielleicht gar nicht so möglich ist, eigentlich das zu standardisieren, weil es immer sehr individuell ist und sehr kontextabhängig mit Absatz oder Wörter et cetera und so?

Max Griesmayer
Es ja, es gibt viele unterschiedliche Ansätze, glaube ich, die jetzt in den letzten 23 Jahren probiert worden sind, gepublisht worden sind und ich glaube schon immer wieder zu lesen, dass sich manche einfach für für generelle Fälle besser eignen.

Patrick Roith
Mhm.

Max Griesmayer
Oder auch bessere Ergebnisse liefern. Aber es ist halt auch ein Zusammenspiel von vielen Komponenten und.

Patrick Roith
Mhm.
Mhm.

Max Griesmayer
Man will jetzt nicht mit einem Framework, glaube ich, immer das beste Ergebnis liefern können, aber es wird, glaube ich, schon Sinn machen, dass man ein Framework hat. Man weiß, das liefert in den meisten Fällen sehr gute Ergebnisse.

Patrick Roith
Ja OK, also auch bezogen.

Max Griesmayer
Ja, weil es gibt dann immer noch den Weg, dass man sich dann selbst trainiert und für sein eigenes Kerngebiet eigene spezialisierte Vektoren bastelt.

Patrick Roith
Ja.
Ja, okay.

Max Griesmayer
Aber das ist dann.

Patrick Roith
Und das ist aber datenstrukturunabhängig meinst du das jetzt also auf uns strukturierte und strukturiert trifft das beides zu oder ja.

Max Griesmayer
Genau das, das trifft dann oft auf Themen zu, also ich weiß, es gibt so ein Padding, zum Beispiel für wissenschaftliche Daten, was für für Rechtsdaten es gibt halt, welche die besser für Englisch sind, welche welche, die besser für Deutsch sind also jetzt allein bei der dieser Vektorisierung.

Patrick Roith
Mhm.
Mhm.
Ja.

Max Griesmayer
Und so ist es dann.

Patrick Roith
Mhm.

Max Griesmayer
Ja, natürlich dann im im Kleinen im Detail geht's dann.

Patrick Roith
Okay.

Max Griesmayer
Kann man das sehr, gibt es sehr viel kleine Stellschrauben, an denen man noch mal zum besten Ergebnis kommen kann, aber generell 90% der Anwendungen sage ich.

Patrick Roith
Ja.
Mhm.

Max Griesmayer
Brauchen diesen Detail gerade gar nicht?

Patrick Roith
Ja, OK verstehe passt und vielleicht werden wir noch mal kurz auf so die Tool Landschaft zu sprechen kommen so welche Tools verwendet sie aktuell? Welche Produkte auch jetzt nicht nur für Data Insessions, sondern auch für Ray et cetera?

Max Griesmayer
Mhm.

Patrick Roith
Wie ist da euer Setup sehr allgemein gesprochen?

Max Griesmayer
Genau prinzipiell entwickeln wir das meiste selbst in Python und verwenden da großteils das Frameway von Langchain, die bieten einfach schon sehr viele Tools und und Funktionalitäten.

Patrick Roith
Mhm.
Mhm.

Max Griesmayer
Schön gerappt an, wo man mit mit mit mit mit wenigen Schritten mal sich so eine simple LNM Pipeline zusammen programmieren kann.

Patrick Roith
Mhm.
Mhm.

Max Griesmayer
Aber ob man dann trotzdem alles in eigener Hand hat, wenn man eben dann unterschiedliche Datenquellen anbinden will oder unterschiedliche Storages hat?
Oder eigene APIS in den APIS abrufen möchte, und da kann man wirklich hat wirklich alles in der in der eigenen Hand und da und da Lösungen zu zu generieren.

Patrick Roith
Ja.
Mhm.

Max Griesmayer
Sonst gibt's im Unternehmen einige Tools, sich den Lohnern Wiederzuwenden.

Patrick Roith
Mhm.

Max Griesmayer
Von Datenbanken begonnen aber wir im Testing Grad verwenden viel open Source tools Datenbanken also wenn wir jetzt gerade die Kraft Datenbanken sind weg, dass du chroma DB.

Patrick Roith
Mhm.

Max Griesmayer
Man halt.
Die sehr, sehr, sehr lightrade ist zum Testen, wo man das Abwägen kann, die schnell genug ist für für kleine Use Cases genau. Thema war dann in Produktion, was nächstes Jahr passieren, wird man schon wahrscheinlich deine leistungsstärkere und, und und.

Patrick Roith
Ja.
Mhm.

Max Griesmayer
Vielleicht auch sogar eben von vom vom Infrastruktur Team gehostete Datenbank brauchen werden.

Patrick Roith
OK, vielleicht noch mal ganz kurz einen Schritt einen Schritt zurück im WG also das sagt

Langchain, verwendet sie auf jeden Fall als Framework was was sind da die Tools oder die Funktionen, die sie von Langchain verwendet?

Max Griesmayer
Also Vector Store.
Ja.
Ja.
Prinzipiell.

Patrick Roith
So vektorisierung oder et cetera sowas in die Richtung.

Max Griesmayer
Genau was ist dann die sowohl die Kommunikation mit diesen Grafendatenbanken?

Patrick Roith
Mhm.

Max Griesmayer
Dass auch die Vektorisierung das aus den beiden.
Wobei da verwenden wir unterschiedlich also so ein ganz kleines Modell, das das das Lokal läuft als auch von OP me I der Flagship Modell, das wir ein bisschen testen können, wie gut die funktionieren und das ist auch so, dass man sagt Plugin Plugout dann halt nur sagen. Wir gehen in das oder in das und später werden wir eventuell auch unser eigenes, größeres embedding Modell dann in der eigenen Infrastruktur laufen haben und dann können wir das Inland Chain quasi ist es nur ein ein Parameter, die wir ändern müssen und es funktioniert alles wie davor auch.

Patrick Roith
Mhm.
Mhm.

Max Griesmayer
Genau und dann auch wenn man jetzt Richtung Agents schaut, ist es so, dass Langchain gibt es ein Schwesternprodukt, das ist der Langgraph, da kann man sich schön visualisieren und wäre dieser dieser Baustelle, die man dann programmiert hat, für einen Agent quasi zusammenstöpseln und nimmt dann.

Patrick Roith
Mhm.

Max Griesmayer
An der einen oder anderen Verzweigung, die die Möglichkeit geben, selbst entscheidend, was er, was er tun machen und genau.

Patrick Roith
Okay.
Mhm, OK, weil du es noch mal kurz angesprochen hast vorher und ich es zuerst nicht gefragt hab bezüglich Datenbankstruktur was? Was ist an an der Datenbankstruktur oder was wäre wichtig, weil du auch also.
Relationaler, Datenbank et cetera und und Graph, weil du das kurz angesprochen hast, vielleicht kannst du auch noch ganz kurz was sagen.

Max Griesmayer
Ja, also prinzipiell ist es wichtig, dass da der Kontext wieder stimmt das heißt, es braucht irgendeine Art von Datenkatalog, ein Data Limage oder irgendeine Info, dass wenn ein LM jetzt quasi selbst sich das beziehen sollte, also das machen wir noch nicht, wenn ich dann bei der.

Patrick Roith
Mhm.
Mhm.
Mhm.

Max Griesmayer
Auch nah zu Computer und Use Case haben, wo wir dir das LM auf die Daten mal zugreifen lassen wollen aber.

Patrick Roith
Mhm.

Max Griesmayer
Da ist es so, dass eben der Kontext da sein muss, dass ich auch diese Met Daten rundherum damit überhaupt ein System entscheiden kann, wo es jetzt die Daten herbekommt.

Patrick Roith
Mhm, okay.

Max Griesmayer
Und wie ist dann also welche Felder, welche Spalten dann, was bedeuten und wie man dann quasi an an an Informationen kommen kann in einem Jahr?

Patrick Roith
Ja.

Max Griesmayer
Also es ist mehr, dann die die.
Benamsung wahrscheinlich, der der Spalten je besser die sie einleuchtender, die ist Benennung, der der der Tabellen und halt der Kontext, den man dazu geben kann. Das ist entscheidend, damit man gute Ergebnisse findet.

Patrick Roith
Mhm.
Mhm, OK.

Max Griesmayer
Und natürlich ist immer gut, wenn wenn der Inhalt auch ein richtiger und sinnvoller ist, weil sonst ja.

Patrick Roith
Ja, verstehe OK.

Max Griesmayer
Hat man ganz anders so viel?

Patrick Roith
Vielleicht noch relativ schon schon zum Ende wie siehst du die die Entwicklung generell von von Reg und auch der der Datenlandschaft, der Datenstruktur, so in den nächsten 2 bis 3 Jahren. Du weißt jetzt auch was, was sich in den letzten ein Jahr einen ein bis 2 Jahren. Geändert hat. Wie siehst du das oder was, was ist so deine dein Ausblick?

Max Griesmayer
Na ja, kommt es ist, kommt drauf an, wo man wo man dann reinschaut, aber prinzipiell glaube ich, dass derzeit noch oder jetzt gerade halt in diesem Hype sehr viel verkauft wird, wo eigentlich nur wenig dahinter steckt mit einem schönen Maschall drauf.

Patrick Roith
Hm.

Max Griesmayer
Weil mit Technologie an sich schon so so stark ist, aber wo jetzt nach und nach auch schon da oder dort, wo ein bisschen zum Bröckeln beginnt, weil also am Anfang sind oft die Leute

unzufrieden sind. Gerade diese automatischen Kundensupports oft dann Blödsinn ausgeben, oder?

Patrick Roith
Ja.

Max Griesmayer
Da gewisse Security Ebene gefehlt hat, das dann.
Die NLMS dann harmful, sage ich mal Content wiedergeben da, da wird gerade viel gearbeitet. Ich glaube nicht, dass die Systeme jetzt noch in den gleichen großen Schritten besser werden, wie sie es die letzten 3 Jahre gemacht haben.

Patrick Roith
Bitte.
Mhm.

Max Griesmayer
Und ich glaub, dass es jetzt eben dazu kommt, dass man gewisse Strukturen Regelungen kommen.

Patrick Roith
Mhm.

Max Griesmayer
Wie man das System an sich einsetzt und gerade Richtung reg, glaube ich, ist das schon, was ein Ansatz, der gekommen ist, um zu bleiben, wo man sehr viele.

Patrick Roith
Mhm.

Max Griesmayer
Reg Lösungen für unterschiedliche?
Use cases sehen werden.

Patrick Roith
Mhm.

Max Griesmayer
Und wie auch bei der klassischen EI davor ist es nur so, dass viele Firmen einfach ihre Daten noch noch noch nicht im Griff haben und dann noch vorarbeitet jetzt geleistet werden muss, bis man das sinnvoll dann.

Patrick Roith
Ja.

Max Griesmayer
Ja, diese Tools verwenden kann.

Patrick Roith
Mhm, weil ich mich ja auch mit so Design principles dann beschäftige, weil es eben auch standardisiert sein soll et cetera was ist aus deiner Sicht so? Was sind so die wichtigsten Punkte oder die wichtigsten Themen. Stichwort jetzt Automatisierung zum Beispiel oder Transparenz auch von seinem Framework oder eben auch wieder.

Max Griesmayer
Mhm.

Patrick Roith
Verwendbarkeit. Dass man es für andere News Cases verwenden kann was ist da für dich so super essentiell?

Max Griesmayer
Ich glaube, so eine Wiederverwendbarkeit ist sicher.
Sicher wichtig, wenn man so ein Framework erstellt, dann möchte man auch, dass das dann in.

Patrick Roith
Mhm.

Max Griesmayer
Ich mein, du definierst dann ein Bereich wo, wofür es dann gedacht werden soll oder? Wenn es generell gelten soll und dann soll es auch generell funktionieren und dann wahrscheinlich in diesen vielen Schritten, die so ein so ein Rack Zyklus hat.

Patrick Roith
Ja.

Max Griesmayer
Ah.

Patrick Roith
Mhm.

Max Griesmayer
Wird es dann auch immer unterschieden, also Abzweigungen geben müssen, weil nicht alle die gleichen Datenbanken verwenden oder die gleichen von den gleichen Herstellern und die gleichen Modelle hinten raus? Aber genau die Schritte dorthin?

Patrick Roith
Ja.

Max Griesmayer
So.

Patrick Roith
Mhm.

Max Griesmayer
Gut, es geht, glaube ich dann dann zu beschreiben, und und da auch vielleicht ich glaube, es gibt dann zu den einzelnen Subthemen oft schon viele Infos, vielleicht da auch dann zu vergleichen was wo funktioniert hat oder nicht funktioniert hat, was man auf einen Blick sieht und so ein Baukasten hat auch.

Patrick Roith
Mhm.

Max Griesmayer
Das die Schritte, den bräuchte ich nur, wenn ich jetzt beides keine Ahnung diese Datenformate hab den Schritt könnte ich mir sonst sparen und genau.

Patrick Roith
Ja.
Also Transparenz im Endeffekt kann man sagen oder ja, Mhm.

Max Griesmayer
Genau Transparenz und ich glaube genau und ich glaube, dieser Fokus auch eben auf den im Chat, also wie komme ich zu dieser sauberen Datenbasis?

Patrick Roith
Mhm OK, ja super, perfekt, super dann wir sind schon am Ende jetzt noch vielleicht die Abschlussfrage gibt's noch Themen oder Punkte, die wir jetzt nicht angeschnitten haben? Bezogen auf das Thema meiner Masterarbeit wo du sagst das ist vielleicht noch interessant oder wichtig oder spannend, oder?
Eine Herausforderung oder keine Ahnung?

Max Griesmayer
Ich glaub herausfordernd wird schon auch das das das Vektorisieren oder wie und welche Daten man vektorisieren will, wenn man hinsichtlich dann relationaler Daten.

Patrick Roith
Mhm.
Mhm.

Max Griesmayer
Also das ist schon ein Punkt, wo ich glaub da.

Patrick Roith
Mhm.

Max Griesmayer
Unterschiedlichen Datenformaten ob man da nicht unterscheiden sollte, wie man es vektorisiert oder ob man ganze Tabellen und Infos vektorisiert zum Beispiel und dann ah in dieser Tabelle doch wieder dann relational, vielleicht mit Abfragen sich was raussucht?

Patrick Roith
Ja.
Ja.
Mhm, das heißt du meinst doch konkret im Endeffekt die, die der Ansatz, wie man eben strukturierte und unstrukturierte Daten vektorisiert, dass das vielleicht nicht ein Standard sein könnte, sondern dass man das eben anders einen anderen Ansatz da hätte pro Struktur.

Max Griesmayer
Ja.
Genau.
Genau ob man sich sogar das die ganze Tabelle an sich auch strukturiert quasi so eine hierarchischen Form wieder, dass man sagt OK man also vektorisiert meine ich, man hat die Tabelle und dann den den Inhalt zu beschreiben und den zu vektorisieren interessant, weil der ein anderer Punkt, den ich da auch vergessen hab in.

Patrick Roith
Ja, Mhm.
Ja.
Mhm.

Max Griesmayer
Was jetzt mit NLMS auch möglich ist, ist eben, dass man die Bilder in Dokumenten.

Patrick Roith
Mhm.

Max Griesmayer
Sich quasi auch dann von am Ende beschreiben lässt und dann diesen beschriebenen Text in der Datenbank dann vektorisiert, um quasi Inhalt von Bild auch auffindbar zu machen.

Patrick Roith
Mhm.
Ja.
Ja, ja OK, verstehe Mhm.

Max Griesmayer
Genau und so Ähnlichkeit geht das dann vielleicht also könnten wir es auch mit mit Tabellen in relationalen Datenbalken lösen, dass sich dann die genau bei dieser Vektorsuche dann die Tabelle rauskommt und dann weiß ich OK ich muss mit der Tabelle.

Patrick Roith
Ja.

Max Griesmayer
Kommunizieren oder den Inhalt dieser Welle je nachdem, wie groß die ist, ja.

Patrick Roith
Mhm.
Ja voll OK das heißt, dass man eigentlich Tabellen so ähnlich behandelt wie Bilder, kann man sagen, oder?

Max Griesmayer
Genau was ich irgendwie schafft dann eben, wenn es ein Bild schafft, dann den ja und 23 Zeilen Kontext zu erzeugen, den dann wieder in einem Vektor darzustellen das gleiche mit der Datenbank mach und eventuell hab ich dann automatisiert mach weil. Oft sind so relationale Datenbanken und Schemas nicht sehr gut dokumentiert oder beschrieben.

Appendix C: Interview Transcript – Data Integration Team Lead

DanielaPatrick Interview-20251110_140118-Besprechungsaufzeichnung

10. November 2025, 01:01PM

47 Min. 3 Sek.

Patrick Roith Transkription gestartet

Patrick Roith
Ich glaub ja, jetzt ist immer immer aufzeichnend, glaub ich muss man das machen zur Bestätigung.

Daniela Mandl
Haas.

Patrick Roith
Es damit du damit du fein ja genau Vollmacht, auf jeden Fall Sinn also erstmal vielen Dank, dass du dir die Zeit genommen hast für das Interview genau es geht kurz noch mal gesagt um meine Masterarbeit um den Problem Space, um auch eben praktische Erfahrung Berufserfahrung.

Daniela Mandl
Ah ja, ja gut, das macht Sinn macht Sinn.
Ja, sehr gerne.

Patrick Roith
Erfahrung mit einzubeziehen, das Thema noch mal ganz kurz heißt Drake Inchestion Framework Standardising the Fusion of Hatrogenes Structured and Unstructured Enterprise Data. Und genau dadurch, dass Du im Data Integration Team bist, hätte ich da eben so ein paar Fragen vorbereitet.
Und genau das Ziel des Interviews im Endeffekt ist einfach ein besseres Verständnis aus der Praxis zu bekommen. Auch die Pain Points Herausforderungen zu verstehen und aufzuzeigen beziehungsweise auch zu sehen, woran ihr gerade arbeitet, was so euer normaler Flow ist, sozusagen bei diesen ganzen Data Integration Themen.
Und genau ich würde dann einfach mal gleich reinstarten es gibt auf jeden Fall kein falsch oder kein richtig du kannst jederzeit natürlich auch immer zwischenfragen stellen genau das Interview sollte nicht zu lange dauern, also ich schätze mal so 30 bis 14 Minuten maximal. Genau vorweg zum Einstieg vielleicht kannst du mal ganz kurz deine Rolle im Unternehmen

beschreiben oder sagen was du da machst und deine deinen Bereich kurz noch mal erklären was, was du im Unternehmen machst?

Daniela Mandl
Sehr gerne gut also ich leite das Tate Integration Team, das sehe ich gerade vorher schon erwähnt das macht das Team grundsätzlich. Wir integrieren aus sehr vielen verschiedenen Datenquellen.
Grundsätzlich öffentlich rechtliche, sichtbare Daten also in erster Linie strukturierte Daten, die an sich verfügbar sind, nicht unbedingt frei verfügbar, also nicht unbedingt kostenfrei verfügbar.
Nicht kostenlos, aber aber grundsätzlich frei verfügbar sind. Ja und versuchen da. Informationen über Personen, Organisationen, ja relevanten, sag ich mal Objekten zusammen zu sammeln und und zusammen zu finden ja also.

Patrick Roith
Mhm.

Daniela Mandl
Es geht da im Prinzip darum, aus verschiedenen Quellen dieselben Personen oder Organisationen zusammenzufinden und quasi so eine Art Profil zu erstellen, wo aus verschiedenen Bereichen Daten zusammenkommen.

Patrick Roith
Mhm.

Daniela Mandl
Aber auch aus denselben Bereichen also man muss auch sagen es geht auch darum, dass man zum Beispiel eine Person, die im österreichischen Firmenbuch an mehreren Unternehmen beteiligt ist, zum Beispiel auch als eine Person darzustellen und nicht.

Patrick Roith
Mhm.

Daniela Mandl
Als viele verschiedene Personen ne also ein?

Patrick Roith
Mhm.

Daniela Mandl
Patrick, der der Patrick, der mir da gegenüber ist, wenn du jetzt an mehreren Unternehmen

beteiligt wärst, dann sollte man auch erkennen, dass du dieselbe Person bist, also das ist ja dann relativ.

Patrick Roith
Und?
Ja.
Mhm.
Mhm.

Daniela Mandl
Relevant, wenn du jetzt zum Beispiel als Vertreter von einem Unternehmen zu einer Bank gehst, einen Kredit erfragst, dass man erkennt, dass du diese Person bist, dass du zum Beispiel auch mit deiner Musterzeichnung und so weiter dich.

Patrick Roith
Mhm.
Mhm.
Mhm.
Ja.

Daniela Mandl
Quasi ausweist und und validierst, dass dass du bist, aber dass du nicht für einen, sondern eigentlich für mehrere Unternehmen stehst. Im Endeffekt zum Beispiel, Das ist ein ein ein ein ein einer von sehr vielen Anwendungsfällen, ja.

Patrick Roith
Mhm.
OK ja.
Sehr schön.

Daniela Mandl
Und tatsächlich weiß ich gar nicht alle Anwendungsfälle, die da draußen bestehen oder so, das sind so diese diese ja wir, wir stellen halt Informationen, würde ich sagen, das ist nämlich ja eben auch dieser Unterschied zwischen ich hab Daten mach Informationen daraus.

Patrick Roith
Mhm ja.

Daniela Mandl
Dieser Unterschied man sagt man man, man fischt Daten aus vielen Ecken zusammen und generiert damit ein ein ein Informationspaket und nicht nicht nur die einzelnen Fakten genau.

Patrick Roith
Mhm.
Mhm.
Ja, perfekt super vielen Dank schon mal für die für den kurzen Überblick und auch schon den Einblick auf jeden Fall vielleicht noch mal so allgemein gesprochen habt ihr in eurem Team oder in deinem Team Endeffekt jetzt aktuell?

Daniela Mandl
Mhm.

Patrick Roith
Schon Use Cases und jetzt muss jetzt nicht zur Datenverarbeitung sein. Da war einfach sehr allgemein oder generell, wo sie schon generative EI verwendet, also Chatbots oder Assistance et cetera beim Programmieren oder bei anderen Tätigkeiten sehr high Level gehalten.

Daniela Mandl
Mhm so was wir auf jeden Fall verwenden also für 5 wir sind ja mehr, sind ja Java und und also wir wir programmieren mit Java und nutzen SQL und ich sag mal die die ID, die typischerweise von den meisten Java Entwicklern verwendet wird ist.

Patrick Roith
Mhm.

Daniela Mandl
Internitchay und da gibt es ja auch einige EI Assistance integriert auch in der IDI, die wird auf jeden Fall auf jeden Fall verwendet, genauso wie wir ja einen.

Patrick Roith
Mhm.
Mhm.

Daniela Mandl
JGBT Account aus dem Firmenkontext haben, den wir auch nutzen genau ja, also das ist immer mal auf jeden Fall bekannt, dass wir die gar nicht so selten nutzen, manchmal aber auch ziemlich viel Blödsinn auspucken muss man auch sagen. Also es ist.

Patrick Roith
Ja, Mhm.
OK ja super passt perfekt, klingt gut, sehr fein ja.
Ja, toll, man muss immer abwägen, aber zu als Unterstützung auf jeden Fall wahrscheinlich ziemlich hilfreich auch und ja.

Daniela Mandl
Genau also ein einer der großen Dinge, wo man sagt, wo es, wo es sehr schnell merkbar ist ist, wenn man man sagt, man möchte einfach nur irgendwas machen, was was einfaches zum zum Start mit irgendeiner.

Patrick Roith
Mhm.

Daniela Mandl
Programmiersprache oder mit einem Framework oder mit einem Thema, dass man so quasi diesen diesen dieses Helferlein für den Staat bekommt, also so ein kleines Lauffähiges Snippet, das manchmal für mühsam sein kann, oder in der Vergangenheit oft mühsam war, kriegt man relativ schnell daher gezaubert.

Patrick Roith
Ja.
Mhm ja.

Daniela Mandl
Raubert quasi und das weiß ich, dass relativ hilfreich sein kann.

Patrick Roith
Mhm ja.
OK super, vielleicht dann noch so ein bisschen Richtung Datenlandschaft wie würdest du im Überblick wirklich so sehr high Level beschreiben? Jetzt wie ist die Datenlandschaft im Unternehmen aktuell? Also welche Schnittstellen habt ihr? Oder ja mit welchen Schnittstellen arbeitet ihr, welche Datenquellen gibt?
Jetzt jetzt nicht so konkret wie viele oder welche konkret, sondern mal sehr, sehr im Überblick oder mit welchen Tools die andere Schnittstellen wieder haben et cetera wie würdest du das so kurz beschreiben mal?

Daniela Mandl
Mhm.

Also man kann sich das in etwa vorstellen, als es gibt. Viele Anbieter von grundsätzlich Daten, die ja entweder noch alte, sag ich mal so Schnittstellen.

Patrick Roith
Mhm.

Daniela Mandl
Verfügung stellen also ist eher eine Technologie, die schon etwas älter ist? Im Idealfall sind es eher restschnittstellen. Das ist eher das Gängigere. Neuere Modell auch nicht mehr neu, aber ein bisschen mehr State of the Art also die sind so diese 2 typischen Schnittstellen die.

Patrick Roith
Mhm.
Mhm.
Passt ja.

Daniela Mandl
Die wir beide nach wie vor verwenden, ja, also als Quellen, genauso wie man auch sagen muss, dass wir auch einfach Daten verarbeiten, die wir als Excel bekommen ja, also von einer Kammer, weil wir.

Patrick Roith
Mhm.
Mhm.

Daniela Mandl
Ja, das das das sind genauso nicht. Die Ärztekammer zum Beispiel schickt uns eine Liste mit Ärzten, ja per Excel, die wir verarbeiten, ja instrukturiert davon genau.

Patrick Roith
Ja.
Mhm, Mhm, Mhm in Instrukturatorform oder Instrukturatorform OK, Mhm Mhm.

Daniela Mandl
Also Excel oder CSV muss man nur sagen es ist nach wie vor eine sehr, sehr, sehr gänkende Quelle. Die Rest Schnittstellen sind ja typischerweise json Formate und so bisher grundsätzlich XML.

Patrick Roith
Mhm.

Daniela Mandl
Genau und gut Rest kann manchmal beides ja also aber genauso gut könnten da ja auch PDFS und Co über die Schnittstellen geliefert werden, was auch so passiert.

Patrick Roith
Mhm.
Ja ja.
Mhm.

Daniela Mandl
Muss man aber auch sagen das sind dann vielleicht nicht die Daten, die wir, die wir dann explizit weiterverarbeiten, also PDFS Phasen ist, so der Unangenehmste weg, den man gehen muss, weil man nicht anders kann im Idealfall.

Patrick Roith
Mhm.
Mhm ja.
Mhm.

Daniela Mandl
Ist, würde ich sagen, immer strukturierte Art und Weise zu bevorzugen.

Patrick Roith
Ja, OK und speichern tut sie die ganzen Daten in der Datenbank oder habt ihr da andere Möglichkeiten, oder wie ist das bei euch?

Daniela Mandl
Genauso grundsätzlich legen wir typischerweise einfach mal mal Files abholen, mal Files ab also es ist eh auch ein mal relativ typischer Weg in einer Pipeline, wo man sagt OK, es sind Dinge, die die incoming sind. Die Preprocessed werden, die vielleicht umgewandelt werden in ein einheitliches Format.

Patrick Roith
Mhm.
Mhm.

Daniela Mandl
Also was auch sehr oft passiert ist, man sagt, man hat irgendwie mehrere verschiedene Eingangsformate zum selben Thema bringt die auf dasselbe Format sagt OK. Wir bringen die auf ein XML Format in eine Struktur, die die gleiche ist.

Patrick Roith
Mhm.
Ja.
Mhm.
Mhm.

Daniela Mandl
Das immer gleich aussehende XML zum Beispiel ja also das ist relativ gängig. Nur mal was sagen Sie ist halt sehr oft abzuwägen, ja so je nachdem wieviel Quellen man da vielleicht auch neu anbindet und neue dazu kommen.

Patrick Roith
Ja.
Mhm.

Daniela Mandl
Man weiß OK. Man verarbeitet diese Quellen täglich vielleicht oder wöchentlich monatlich Verhältnis zu vielleicht etwas, was man nur einmal bekommt, oder Stammdaten, die man einmal im Jahr bekommt oder so gibt es immer einzeln zu bewerten.

Patrick Roith
Mhm.
Ja.

Daniela Mandl
Hat dann oft was damit zu tun, auch wie die aufgebaut sind.

Patrick Roith
Mhm, OK, super die nächste Frage wäre dann welche welche Systeme oder Technologien nutzt ihr aktuell gerade eben, um strukturierte Daten oder auch unstrukturierte Daten zu verarbeiten beziehungsweise zu integrieren. Du hast jetzt auch schon mal gesagt ihr. Verwendet hauptsächlich oder ihr arbeitet hauptsächlich mit strukturierten Daten. Wie ist da so dieser Umgang auch zum Beispiel, wie du gesagt hast zu XMLS vereinheitlichen was was was verwendet ihr da? Welche Systeme oder Technologien, welcher Ansatz?

Daniela Mandl
Mhm.
Genauso da gibt's ja verschiedene C Varianten ja, was, was wir jetzt aktuell relativ oft verwenden, ist eigentlich, dass man sagt, man hat Java Komponenten die die, die wir selbst geschrieben haben, weil die ja angepasst sind auf die Inhalte.

Patrick Roith
Hm.
Mhm.

Daniela Mandl
Halte oder auf die auf die Strukturen hier sind wir mal Map von hier da von von A nach B das ist ein ein relativ typischer Weg, aber auch ein mühsamer muss man noch sagen es ist nicht unbedingt der der Aufwandsschonendste weg.

Patrick Roith
Mhm.
Ja.
Ja.
Mhm.

Daniela Mandl
Dann verwenden wir zum Beispiel auch noch ein ein Tool, das das nennt sich Lobster. Das kommt eigentlich aus der Logistik, das ist ein da gibt es eine eine Art Datenplattform, ja.

Patrick Roith
Mhm.
Mhm.

Daniela Mandl
Da ist auch diese sind so zum Beispiel Anbindung von SMTP sind integriert, so eine gibt es eine Möglichkeit, FTP oder SFTP Server zu verwalten Partnerkanäle mit.

Patrick Roith
Mhm.
Ja.

Daniela Mandl
Kunden oder Lieferanten zu verwalten und da kann man zum Beispiel eben auch so ich würde jetzt mal sagen, ETL Strecken mehr oder weniger modellieren und somit dann auch.

Patrick Roith
Mhm.

Daniela Mandl
Gibt es auch die Möglichkeit, Daten zu konvertieren, also von einem Format in ein anderes,

was wir tatsächlich eher nicht verwenden, ist diese ganze Microsoft Power Apps schiene. Ich glaube, das wäre auch ein manchmal ganz, ganz geschickter weg.

Patrick Roith
Mhm.
Okay.
Mhm.
Mhm.

Daniela Mandl
Vor allem wenn man sagt, man ist sehr auf der Microsoft Genie unterwegs, dass wir nicht so sehr sind, ja also wir nutzen zwar ein manchmal ein Excel als input Format, aber wir sind dann nicht in einer Microsoft Welt unterwegs, sag ich jetzt mal ne.

Patrick Roith
Mhm.
Mhm.
Ja, ja, okay.

Daniela Mandl
Das das wäre sicher auch ein Punkt, was wir heuer evaluiert haben, ist von Apache gibt es da 2 Frameworks? Apache Camble ist auf der auf der einen Seite unter Apache Nifile.

Patrick Roith
Mhm.
Mhm.

Daniela Mandl
Wo wir uns wahrscheinlich für Neifer entscheiden, ist aber noch in einer PUC in einem PUC in einer noch nicht in einer, also produktiven Phase, wo wir wahrscheinlich einerseits diesen diese Lobster Data Plattform ablösen.

Patrick Roith
Ja.
Ja.

Daniela Mandl
Lösen werden und wo wir grundsätzlich einige Verarbeitungen in diese Richtung umstellen. Also ich würde sagen, das ist am ehesten vergleichbar mit einem typischen ETL, also extract, Transform und load.

Patrick Roith
Mhm.
Mhm.
Mhm.

Daniela Mandl
Framework.

Patrick Roith
OK und weil wir jetzt noch kurz über die strukturierten Daten gesprochen haben was würdest du sagen ist so, dass die die größte Herausforderung oder was sind so so Probleme, die dir immer wieder mal aufgefallen sind und aufgetreten sind, wenn man strukturierte Daten vereinheitlichen möchte, fusionieren möchte?
Standardisieren möchte was fällt dir das ein, was sind so die die schwierigsten oder größten Themen?

Daniela Mandl
Die pean Points.

Patrick Roith
10 points genau.

Daniela Mandl
Also das eine ist hat halt grundsätzlich sehr oft sehr unterschiedliche Datenqualitäten, also das ist sicher einer der größten Punkte und das ist eigentlich glaube ich völlig irrelevant. Ob strukturierte oder unstrukturierte Daten dieses Thema kommt ja immer wieder, also sowohl da wie dort gilt.

Patrick Roith
Mhm.
Mhm, OK.
Und?

Daniela Mandl
In die Qualität der Daten also je schlechter die Qualität der Daten wird, desto schwieriger wird das auch, damit irgendwas sinnvolles zu zu machen. Ja, das jetzt bei unserem in unserem Fall denn in Denziell eher.

Patrick Roith
Ja.

Daniela Mandl
Matching oder zum Beispiel eben das Resurfen von Personen ist oder von Organisationen fällt das oft einmal schwer. Ne also mit der Qualität steht und fällt eigentlich relativ relativ viel.

Patrick Roith
Ich.
Ja.
OK.

Daniela Mandl
Dann hat man natürlich auch ein anderes Thema man kriegt dann oft Daten, die wirken wie ein gewisses Modell also man versucht sich ja dann eigentlich aus diesen strukturierten Daten oder auch unstrukturierten ja.

Patrick Roith
Mhm.

Daniela Mandl
Vor allem aus den strukturierten. Das Modell auszudenken, wie das eigentlich auf der anderen Seite modelliert war.

Patrick Roith
Mhm.
Hm.

Daniela Mandl
Damit man's versteht ja, in welcher Form eigentlich diese Daten ursprünglich mal abgelegt waren, um sich so strukturiert zur Verfügung zu stellen. Und je mehr wir diesem Originalmodell kommen.

Patrick Roith
Mhm.
Mhm.
Mhm.

Daniela Mandl
Das tut leicht ist auch das sinnvoll zu verarbeiten? Spannend ist dann, wenn man dann drauf kommt, wenn man zum Beispiel einfach mit mit denen kommuniziert, ja ist immer die Frage, ob man mit der mit dem Gegenpart oder mit dem Lieferanten kommunizieren kann oder ob das seine.

Patrick Roith
Mhm.

Daniela Mandl
Anonyme Stelle sag ich jetzt mal ist, wo man nicht wirklich was rausbekommt, dass die zum Beispiel einen Fehler in ihrem Modell haben.
Also wo du sagst OK, da werden Daten in einer nicht normalisierten Form gespeichert oder? Die haben dann nur ein Feld und bräuchten aber eine eine n zu m Beziehung, ne oder solche solche Dinge da kommt man dann drauf an Kinder irgendwie.

Patrick Roith
Ja.
Ja.

Daniela Mandl
Passen diese Daten inhaltlich nicht zusammen? Aber es wirkt so ja und erst in der Tiefenanalyse kommt man drauf, irgendwas passt da nicht ja, also das sind das sind finde ich.

Patrick Roith
Ja ja.
Mhm.
Okay.

Daniela Mandl
Schwierige Challenges, die dann auch manchmal nicht lösbar sind, also weil ja dann vielleicht die richtigen Daten gar nicht kommen können, ne also das das das ist was was auch.

Patrick Roith
Mhm, okay.
Ja, OKOK.

Daniela Mandl
Auch manchmal auffällt ja dann muss man sagen auf viele Dinge die, die wir als Mensch irgendwie so aus dem Kontext herauslesen.

Patrick Roith
Mhm.

Daniela Mandl
Sind halt oft einmal viele Maschinen nicht einfach so erkennbar, ja, wobei man auch sagen muss manchmal auch viele Menschen nicht so klar ne, also man sagt man hat da irgendwie.

Patrick Roith
Hm.
Ja, stimmt.

Daniela Mandl
Eine Person und man möchte irgendwie verstehen, OK, was sind denn da vor und Nachnamen zum Beispiel einfach nur einen einen Namen zu zerteilen, in seine Bestandteile in seine Titel in seine Vornamen, seine Nachnamen und dann kommt man dann irgendwie auf kulturelle Unterschiede auf.
Sprachliche Unterschiede auf ja, dann sagt man ist irgendwo im in einem zum Beispiel südamerikanischen Raum, wo, wo es völlig üblich ist, 345 Vornamen sogar zu haben oder genau zum Nachnamen ja also.

Patrick Roith
Mhm.
Ja, Mhm Mhm.

Daniela Mandl
Und sagt OK bei uns führt kaum jemand mehr als vielleicht 2 Vornamen und viel maximal einen Doppelnamen ne also das sind so ganz unterschiedliche Dinge, die dann auch kulturell oft einen Unterschied machen.

Patrick Roith
Mhm.
Ja, Mhm OK.
Ja, Mhm.

Daniela Mandl
Und die dann aber manchmal so ohne Kontext gar nicht so leicht sind korrekt zu behandeln.

Patrick Roith
Ja, das heißt, man braucht auch oft einfach Kontext, um um solche Sachen auch zu lösen.
Und wenn ich jetzt zum Beispiel noch mal ein bisschen auslollen sag, wenn es um die Fusionierung von strukturierten Daten gibt, was sind so die größten Herausforderungen für dich noch mal auf diese Probleme oder Painbones, die du jetzt angesprochen hast und?

Daniela Mandl
Mhm.

Patrick Roith
Das eben zu standardisieren. Das heißt, wenn man das wirklich sagt OK, man hat jetzt 2 unterschiedliche strukturierte Daten, also Dateien im Endeffekt ja, was sind so die größten Themen von Deinen Pain Points, die du hast?
Um das eben zu standardisieren, würdest du sagen, was sind die größten Herausforderungen?

Daniela Mandl
Ich ich glaub, oft ist es, wenn man sagt, man möchte Daten zusammenführen, dass eben unterschiedliche Quellen unterschiedliche Informationen liefern. Ja, also wenn ich jetzt zum Beispiel auf der einen Seite den Patrick mit dem Geburtsdatum hab und auf der anderen Seite den Patrick.

Patrick Roith
Mhm.
Mhm, Mhm.
Mhm.

Daniela Mandl
Ohne Geburtsdatum, aber dafür mit einer Adresse ja woher weiß ich denn das jetzt, dass das derselbe Patrick ist? Also das ist de facto nicht möglich, ja so also diese unterschiedliche.

Patrick Roith
Ja.
Mhm.
Ja, Mhm.
Ja, ja, ja, okay.
Mhm.
Ja.

Daniela Mandl
Sicher die die Challenge.

Patrick Roith
Mhm, OK.

Daniela Mandl
Und dann hat man natürlich so was wie auch einfach menschliche Fehler. Da hat sich wer vertippt, ja.

Patrick Roith
Ja, ja, stimmt.

Daniela Mandl
Wurde aus 1971 oder so 1917 oder so ja und dann passt das einfach schon nicht mehr zusammen und die Maschine wird es nicht erkennen. Frage mich ob es der Mensch erkennt aber.

Patrick Roith
R.
Mhm, OK.
Ja.
Mhm, siehst du irgendwelche technischen Herausforderungen, die man, denen sich man stellen muss, ich meine das eine ist jetzt mal die Datenqualität und die unterschiedlichen Daten und die Erkennbarkeit und die Identifikation von Daten. Aber auf der anderen Seite, dass man es auch so technisch abbildet, dass man das eben eine Standard hat.

Daniela Mandl
Mhm.

Patrick Roith
Stichwort irgendwie ein Tool oder ein ein Skript im Endeffekt, dass das schafft oder Frameworks et cetera siehst du da irgendwie so ne Hürde?

Daniela Mandl
Mhm und ich glaube, ich glaube, es ist wahrscheinlich im Vorfeld die Hürde, dass man man stuft Qualitäten mal ein und zwar wirklich so, indem man analysiert wie gut sind diese Quellen ja und und dann kann man innerhalb der Qualität vielleicht was machen?

Patrick Roith
Mhm.
Mhm, Mhm.
Mhm, okay.

Daniela Mandl
Glaube ich also, aber was wir auch begonnen haben, ist mehr oder weniger zu flaggen. Ist das eine vertrauenswürdige Quelle oder ist sind das eher schlechte Daten? Ne sind wie wie gut ist diese Qualität von dessen Daten, die können immer noch was falsch drin sein.

Patrick Roith
Ja.
Ja ja.

Daniela Mandl
Aber der Quelle trauen wir mehr als der anderen.

Patrick Roith
Mhm OK, verstehe Mhm vielleicht weil du jetzt noch mal ja.

Daniela Mandl
Und ich glaub, das ist dann oft, das sind dann oft meta Informationen, die man irgendwie mitführt und sind das im Endeffekt typisierungen von den Daten, wo wir sagen OK hinter diesem Typ hinterlegen wir uns auch eine Art Vertrauenswürdigkeit.

Patrick Roith
Ja, ja, ja.
Mhm, ja, OK super verstehe, wenn man jetzt jetzt haben wir schon sehr viel über strukturierte Daten gesprochen. Wenn man jetzt noch mal kurz den Fokus auf unstrukturierte Daten legt weißt du hast gesagt aktuell arbeitet es jetzt nicht so viel mit unstrukturierten Daten.

Daniela Mandl
Oder Datenqualität ja.
Mhm.

Patrick Roith
Aber vielleicht, wenn du so ein paar Beispiele hast und einfach mal jetzt so ziemlich high Level auch überlegst, was sind so für dich die oder was von aus deiner Erfahrung? Die größten Paying Points die größten Herausforderungen, die Probleme eben um unstrukturierte Daten zu zum einen zum Verarbeiten zu integrieren und zum anderen auch eben zu.
Fusionieren und einen Standard darum zu bilden, mehr oder weniger, dass das eben standardisiert funktioniert.

Daniela Mandl
Aber ich glaube, es ist immer ein auch ein Thema von der Datenhaltung und wenn man sagt, man hat zum Beispiel Chasens, die keinem Schema entsprechen, keinen gemeinsamen definierten wie und wo man die hält und wie man die auch sinnvoll exploriert.

Patrick Roith
Mhm.
Mhm, Mhm.

Daniela Mandl
Ich meine, da gibt es ja mittlerweile sehr gängig, die No no Sequel, Datenbanken und Co die sich glaube ich anbieten, für die diese Form von Daten, die wir tatsächlich nicht verwenden, weil wir von der Anwendbarkeit einfach da momentan eigentlich nicht.

Patrick Roith
Mhm.

Daniela Mandl
Den den den Fall haben, ja, also die die Chasens, die wir zum Beispiel aus Rest Schnittstellen wollen, haben grundsätzlich im Normalfall ein Schema.

Patrick Roith
Mhm.
Ja, Mhm.

Daniela Mandl
Gut, man könnte dann natürlich umgehen mit PDFS. Auch Urkunden, also Dokumenten, die in PDF Form sind, wo man sagt OK da, da könnte man etwas extrahieren.

Patrick Roith
Mhm.
Mhm ja.
Mhm.

Daniela Mandl
Ein Jahresabschluss von einer von einem Konzern kann kann stark unterschiedlich sein, ja, also natürlich folgen die, je nachdem, wie diese Firma wie die Größe ist und so weiter unterschiedlichen Regeln, die nach IFS bilanzieren oder nicht zum Beispiel dann gibt es viel strengere Vorgaben.

Patrick Roith
Mhm.
Mhm.
Ja, Mhm.

Daniela Mandl
Haben aber auch da gibt's dann wieder unter also es gibt immer wieder Unterschiede ja auch wenn man dann aus diesen PDFS zum Beispiel wieviel wollen da zum Beispiel Mitarbeiter-zahlen rausholen, ne also das ist vorgeschrieben, dass das da drinnen sichtbar sein muss?

Patrick Roith
Mhm.

Daniela Mandl
Wie das exakt beschrieben ist und ob das abweicht, ob es tabellarisch dargestellt ist, ob es in einem Text ist, das ist dann oft nicht so so eindeutig und dann wieder.

Patrick Roith
Ja.

Daniela Mandl
Gleiche Informationen unter unterschiedlichen Form sogar.

Patrick Roith
Mhm OK gibt es aktuell jetzt Beispiele im im jetzigen Job bei dir im Team, wo sie Dokumente oder PDFS oder eben und strukturierte andere Daten verarbeitet und wenn ja wie?

Daniela Mandl
Ja, wir wir extrahieren eben da jetzt gerade nicht ja also, es gibt Projekte dazu, wo wir das gerade angehen. Du hast jedes Interview mit Max gehabt, wo es um OCR geht das.

Patrick Roith
Ja, Mhm.
Ja, Mhm.
Genau richtig.
Mhm.

Daniela Mandl
Habe ich quasi ausgelagert, da sind wir, sind wir nutzen Nieser.

Patrick Roith
Ja, passt OK.
Ja, perfekt, die die nächste Frage wäre, weil wir jetzt doch sehr viel über uns strukturierte, strukturierte Daten gesprochen haben, vielleicht noch mal kannst du kurz erzählen oder erklären, wieso bei euch im Team bei dir jetzt generell dieser typische Data Injestion pro?

Daniela Mandl
Den Tim.
Hm.

Patrick Roith
Das eben stattfindet also wirklich von der Quelle, wo sie eben Daten abholt bis hin zur Nutzung, dass es eben ein anderes developer Team eben nutzen kann und das muss jetzt nicht wirklich super im Detail sein, sondern wirklich so diese diese Hard Facts im Endeffekt, dass du mal kurz diesen Prozess vielleicht durchgehen könntest, das ist ja super.

Daniela Mandl
Mhm also grundsätzlich würde ich sagen es, du suchst quasi. Es poppt eine neue Quelle auf, kommt in meinen in meinen Aufgabenbereich und und wir such wir evaluieren mal, ob wir die überhaupt zum Beispiel nutzen können ja.

Patrick Roith
Mhm ja.
Mhm.

Daniela Mandl
Am.
Da würde ich jetzt mal sagen, es gibt da oft mal sag mal Wissende im Sinne von dass man sich wahrscheinlich mal denjenigen holt, der sich mit dem Kontext am besten auskennt also es macht schon ein Unterschied um zu.

Patrick Roith
Mhm.
Mhm.

Daniela Mandl
Setzt da jemanden dahinter? Bei der Analyse der mit dem Thema noch nie was zu tun hatte, oder man findet zumindestens jemanden, der auf so einer ähnlichen Ecke schon Erfahrung gesammelt hat also ich glaub, dass das relativ viel ausmacht. Wer sich das ansieht und analysiert und da mal in in die Tiefe versucht.

Patrick Roith
Ja.
Mhm.
Mhm.

Daniela Mandl
Zu graben ja, was, was, was das dann ist und dann ist es oft einmal natürlich auch die Frage wieviel Daten sind das, die man sich da holen kann? Also ist es irgendwas greifbares oder ist es in einem Bereich, den man sich einfach nicht der nicht mehr?

Patrick Roith
Mhm.
Mhm.

Daniela Mandl
Wer denn der nicht mehr überschaubar ist? Ja, ich sag einmal. Je größer der Bereich, desto mehr High Level muss man mal ansetzen, um um analysieren zu können, wird man nicht so in die Tiefe gehen können. Wird man sich vielleicht einzelne Dinge rauspicken und in die Tiefe gehen? Aber.

Patrick Roith
Mhm.
Mhm.
Ja.

Daniela Mandl
Wahrscheinlich wird man sich im großen Mal einen Überblick machen müssen, mal im Großen eine eine Analyse fahren, ist dann natürlich die Frage wie wie leicht sind diese Daten? Im Zugriff kann man sich vielleicht auch an unterschiedliche Ebenen holen.

Patrick Roith
Mhm.
Mhm.

Daniela Mandl
Also das oder muss man sich diese Ebenen erst schaffen, muss man erst mal alle diese Daten holen in Strukturen Gießen, um sie analysieren zu können, hatten wir das heuer zum Beispiel bei einem größeren Projekt. Ich muss da eigentlich müssen wir da erst mal Millionen von Datensätzen holen.

Patrick Roith
Ja.
Mhm.
Mhm.

Mhm, Mhm.
Ja, Mhm.

Daniela Mandl
Und die dann mal verarbeiten, um die sinnvoll analysieren zu können, um überhaupt Aussagen treffen zu können und auch Aussagen über die Qualität sagen zu können, wenn man vielleicht noch gar nicht weiß, was da alles drin ist.

Patrick Roith
Ja.
Mhm.
Ja, okay.

Daniela Mandl
Also das ist dann wird dann je größer die Menge der Datensätze ist und je breiter quasi dann ein so ein Satz ist, desto schwieriger wird es natürlich dann auch zu zu dem Satz.

Patrick Roith
OK.
Ja.
Mhm.
Mhm.

Daniela Mandl
Aussagen zu treffen?

Patrick Roith
OK, das heißt eigentlich es gibt schon bei der Abholung ja im Endeffekt schon diese Challenges und diese Herausforderungen das heißt wenn ihr diese ganzen Darknets aus den unterschiedlichen Quellen abgeholt habt, wie Verfahrt ihr dann weiter damit?

Daniela Mandl
Genauso wenn wir die, wenn wir die Upcode haben und und entschieden haben, ja, das ist eine ist eine Quelle, die wir nutzen wollen, ja, dann startet bei mir im Normalfall ein ein ein ein Projekt, wo man sagt OK man man überlegt sich auf der einen Seite ein bisschen noch hin wohin soll das gehen? Kann man.

Patrick Roith
Mhm.
Ja.
Hm.

Daniela Mandl
Star und dort bisschen integrieren gibt's vielleicht schon ein einen Bereich, auch auch auch in im Datenbank Schema in einem Java Projekt gibt's, da gibt's da schon was, wo man sagt, man dockt an an was Bestehendes ist es jetzt ein? Eine weitere Quelle vom eh schon selben ne?

Patrick Roith
Mhm.
Mhm.
Mhm.
Mhm, Mhm.

Daniela Mandl
Also wir haben da zum Beispiel mal ein Projekt gehabt, da haben wir aus den verschiedenen Sanktionslisten der Welt Personen und Unternehmen Organisationen, die sanktioniert sind, gesammelt.

Patrick Roith
Mhm.
Mhm.

Daniela Mandl
Da haben wir halt mal begonnen mit dem, was für uns am nähesten war, ne, wir haben begonnen mit der.eu, mit der Wayne weil das Resi für unseren Raum der mal spezifisch eher mal auf Österreich oder auf den Dachraum oder maximaldie.eu gerichtet ist.

Patrick Roith
Mhm.
Ja ja.
Mhm.
Mhm.
Mhm.
Mhm.
Mhm.

Daniela Mandl
Struktur das heißt, Wir haben Sie in dieselbe Struktur gegossen, wir haben uns Gemeinsamkeiten gesucht und aber auch unterschiedliche gesucht und haben dann bewertet OK, welche von den Dingen, die vielleicht auch unterschiedlich sind sind die für überhaupt relevant

für uns? Aber dann lassen wir die vielleicht weg, also gerade wenn du sagst du hast Daten, die in unterschiedlichen Strukturen.

Patrick Roith
Mhm.
Mhm.
Mhm.

Daniela Mandl
Kommen gilt sicher zu bewerten brauchst du die alle oder nimmst du eh nur die Gemeinsamkeiten oder sind die Gemeinsamkeiten dann eigentlich wieder zu wenig? Also muss ich sie wieder mehr Nägeln.

Patrick Roith
Mhm.
Mhm darf ich da nachfragen? Ganz kurz war was ist das Ziel oder was war das Ziel im Endeffekt? Das ist gemeinsam in eine Struktur, gehst aus den unterschiedlichen Quellen oder was ist da der große Benefit oder der Vorteil davon?

Daniela Mandl
Also grundsätzlich würde ich sagen hat das dann, wenn du sagst man hat dann laufend die Systeme, die diese Daten regelmäßig verarbeiten möchtest du möglichst wenig Systeme pflegen?

Patrick Roith
Mhm.

Daniela Mandl
Das heißt, du hast eigentlich das Ziel dass sagst OK, du hast mehrere verschiedene, also Varianten vom E gleichen die bringst du in eine Form und alles dahinter funktioniert gleich ja also ich hab ein datenbankschema ich hab einen Job, der das dann importiert der.

Patrick Roith
Mhm.
Mhm.
Mhm.
Hm.

Daniela Mandl
Mehr als diesen und jenen Sonderfall behandelt oder diese und jede Routine, die danach läuft, diese die das dann zum Beispiel mit anderen Daten verbindet, aber wenn je mehr ich

das vorher schon vereinheitlicht, desto weniger muss ich nachher unterschiedliche Varianten davon pflegen.

Patrick Roith
Mhm.
Mhm.
Mhm, OK.

Daniela Mandl
Dafür muss ich sie aber richtig vereinheitlichen, also da ist dann eigentlich so ein ziemlicher, sag ich mal entscheidungspunkt ja, wo man sagt OK was nimmt man mit, was darf man nicht mitnehmen? Was?

Patrick Roith
Ja, okay.
Ja.
Mhm.

Daniela Mandl
Was weicht zu sehr ab oder ist das doch so unterschiedlich, obwohl es ähnlich wirkt, dass man unterschiedliche Wege gehen muss?

Patrick Roith
Mhm.
Mhm, würdest du das Sagen, ist das sehr viel manuelle Arbeit auch noch erforderlich, um das eben herauszufinden oder ist das irgendwie in einer Form automatisiert oder zu einem?

Daniela Mandl
Ich glaube, bei uns ist es schon tendenziell eher manuelle Analyse.

Patrick Roith
Mhm, OKOK, Mhm und Mhm.

Daniela Mandl
Aber ich glaube, es ist dann auch oft man sagt, man hat dann eine Routine, die das Mal verarbeitet.

Patrick Roith
Ja.

Daniela Mandl
Also Kim, man glaubt, man hat es jetzt verstanden, was was da der die Kernessenz ist und

dann lässt man da mal hunderte oder tausende Datensätze mal verarbeiten? Da kommt man aber drauf, aber OK da und da und da und da da gilt das nicht.

Patrick Roith
Mhm.
Ja.

Daniela Mandl
Ja, und dann kann man dann da weiter schärfen, also fein, fein tunen und nachschärfen.

Patrick Roith
Mhm.
Ja, gibt gibt es noch andere Herausforderungen, die dir da einfallen dazu, wenn man diese verschiedenen Datenquellen dann eben zusammenführt?
Die schwierig sind oder die nicht so einfach sind, irgendwie zu meistern dann.

Daniela Mandl
Ja, ich glaube, es ist manchmal auch nicht so leicht zu sagen OK, was ist es denn überhaupt? Ja, also weil also man hat dann irgendwie in einem Modell so irgendwie ein paar Ideen OK das funktioniert so das funktioniert so und gibt dem dann einen Namen, ne damit sie nicht greifbar wird auch so, auch wenn man so in einer objektorientierten denke.

Patrick Roith
Mhm, Mhm.
Mhm.
Mhm.
Mhm.

Daniela Mandl
Base wird man irgendwie versuchen, Objekt verschiedene Objekte mit verschiedenen Attributen verschiedenen Funktionsweisen zu definieren und dann kann man das entsprechend.

Patrick Roith
Mhm.
Ja.
Mhm.
Mhm.

Daniela Mandl
Modulieren, sich vorstellen und dann kommen wir aber vielleicht drauf, passt doch da und dort nicht hinein ja oder wird falsch erkannt ja landet hier gehört aber hier hin.

Patrick Roith
Mhm.
Mhm.
Mhm, Mhm.
Ja, OK verstehe.

Daniela Mandl
Mhm es ist weil dadurch gibt's dann folgefehler, die man nicht die man dann vielleicht erst irgendwann später kennt oder gar nicht, ja also da.

Patrick Roith
Mhm.
Mhm.
Ja.
OK.

Daniela Mandl
OK der Staubsaugerroboter hat beschlossen er möchte jetzt sagen ich werd den kurz.

Patrick Roith
Kein Problem, alles gut.

Daniela Mandl
Wieder auf seinen Bass zurückweisen, weil sonst wirst du mich gleich nicht mehr verstehen. Ich bin gleich wieder da.

Patrick Roith
Ja ja, alles gut, kein Stress, kein Stress.
Mission erledigt?

Daniela Mandl
Ja, Mission erledigt. Es wird nicht staubgesaugt.

Patrick Roith
Ah ja, perfekt vielleicht noch die, die eine Frage anhängen, zu der zu der folgenden Frage jetzt hast du gesagt, jetzt werden diese ganzen Daten aus verschiedenen Datenquellen eben

zusammengetragen zusammengeführt was ist jetzt so der nächste Schritt in der in der Pipeline, wo du sagst?
So werden sie jetzt noch verarbeitet oder bearbeitet, damit sie eben verfügbar sind für für andere Teams, damit sie eben dann brauchbar sind. Was folgt danach noch? Oder?

Daniela Mandl
Also ich würde sagen, es gibt sicher noch vereinheitlichungs Schritte, ja, das ist so das eine, was mir einfällt auf der anderen Seite, dass man versucht, eben Verknüpfungen herzustellen zwischen verschiedenen Daten.

Patrick Roith
Mhm.
Mhm.

Daniela Mandl
Der selben Quelle oder unterschiedliche Quellen?

Patrick Roith
Ja.

Daniela Mandl
Das hat natürlich auch sozusagen quasi ein bisschen dieses Datenspeicherthema ja speichern ist jetzt heutzutage nicht mehr so teuer, wie es mal früher war. Also es hat einen anderen Stellenwert, aber wenn man diese Daten nicht dann so früh wie möglich zusammenführt, muss man später.

Patrick Roith
Mhm.
Mhm.

Daniela Mandl
Umso mehr verbinden ne also ist dann vielleicht auch noch so ein Thema je je jeder sprenkel da quasi alles ist das umso mehr muss man nachher dann aus der Gesamtheit wieder zusammenführen, also vielleicht.

Patrick Roith
Mhm, Mhm.
Okay.
Ja.

Daniela Mandl
Führt man zusammen an an anstellen, wo man vielleicht noch mehr Informationen hat, wenn man noch weniger abstrahiert hat, so das ist ein Thema.

Patrick Roith
Mhm.
Mhm, Mhm, Mhm.

Daniela Mandl
Man hat OK je je je genereller man wird, desto weniger gemeinsamer Attribute hat man ja dann vielleicht auch.

Patrick Roith
OK.
Mhm.

Daniela Mandl
Genau und dann wird man es wahrscheinlich auch sagen müssen. Auf der anderen Seite wie will ich Ihnen das überhaupt zur Verfügung stellen? Also hat man wieder diese Frage welche Modelle habe ich denn da überhaupt zur Verfügung? Welche Modelle will denn mein Gegenüber verwenden?

Patrick Roith
Mhm.

Daniela Mandl
Oder glaube ich, dass es verwenden wird? Ja also, dass man es vielleicht dann auch so eine Sache man hat sehr Daten, die sehr roh sind oder verhältnismäßig recht nah dem Original oder vielleicht sogar exakt das Original widerspiegeln müssen, wenn man sagt, man braucht das um.

Patrick Roith
Wie?
Mhm.
Mhm.

Daniela Mandl
Vielleicht auch rechtlich belastet zu sein?

Patrick Roith
Ja, Mhm.

Daniela Mandl
Und sagt OK, das ist exakt der Datensatz, wie es im Firmenbuch zum Beispiel steht und nicht anders unverändert.

Patrick Roith
Mhm.
Mhm.

Daniela Mandl
Oder ist es ein eine Sache, die vielleicht aggregiert ist und man lasst gewisse Informationen weg, vielleicht auch, weil sie vielleicht doch vielleicht persönlich datenschutzrechtlich problematisch sind?

Patrick Roith
Mhm.
Hm.

Daniela Mandl
Oder?
Weil es vielleicht auch.
Vielleicht eine gewisse Vertraulichkeit mitgegeben, aber wirklich immer gewisse Daten darf man zeigen gewisse sollte man nicht mehr nicht zeigen, oder wurden vielleicht auch sowas wie ausgeblendet? Es gibt vielleicht auch Dinge, die.

Patrick Roith
Eben.
Mhm.

Daniela Mandl
Die angefragt wurden, dass man sie nicht mehr zeigen sollte also.

Patrick Roith
Ja, Mhm.

Daniela Mandl
Diese diese diese Themen muss man ja auch irgendwie behandeln, ja das Recht auf löschen ist das nächste ja, aber da sind wir gerade wenn wir bei personenbezogenen Daten sind, ja sowieso noch einmal in einem ganz, ganz eigenen Thema.

Patrick Roith
Mhm, Mhm.

OK.
Ja.
Mhm.

Daniela Mandl
Ja, aber es ist eigentlich dann immer die Frage welches Modell braucht denn mein Gegenüber, was was wollen? Was will denn der Nutzer von diesen Daten dann tun? Braucht ihr das sehr, sehr aggregiert braucht ihr nur ein paar einzelne Fakten oder braucht ihr besonders viel?

Patrick Roith
Mhm.
Mhm.
Mhm.

Daniela Mandl
Wenn du möchtest ja dann auch eine gewisse Performance gewährleisten eine gewisse Usability, wenn es eine Applikation nutzt, ist nicht ein Paging and Sorting solche Dinge also es ist.

Patrick Roith
Mhm.
Ja.
Mhm, ja, ja okay.

Daniela Mandl
Dann wieder ganz andere Themen, ne.

Patrick Roith
Ja, OK, vielleicht noch jetzt mal kurz wieder einen Schritt zurück bezüglich dieser, weil ja doch das Thema auch bei mir Standardisierung von oder Fusionierung auch von strukturierten und unstrukturierten Daten ist was meinst du ist aus deiner?
Sicht jetzt mir ist schon bewusst, dass jetzt nicht so viele unstrukturierte Daten verarbeitet, aber kunstlich was ist so das große Thema oder was ist notwendig, um wirklich gut strukturierte und unstrukturierte Daten zu standardisieren? Du hast jetzt eh schon auch vieles auch erwähnt mit Metadaten et cetera.

Daniela Mandl
Mhm.

Patrick Roith
Zu arbeiten was sind so die die wichtigsten Hard Facts aus deiner Sicht, wo du sagst OK, das ist wirklich wichtig, dass man das beachtet, um da einen guten Standard reinzubringen?

Daniela Mandl
Ist ja gute Frage.

Patrick Roith
Also wirklich auf die auf den der Fokus wirklich auf die Standardisierung von strukturierten Daten auf der einen Seite die man aufbereitet hat und eben gut aufbereitet hat, auf der anderen Seite diese unstrukturierten Daten?
Was meinst du ist jetzt was könnte helfen oder was wäre wichtig, um diese ganze Fusionierung, um diese oder auch um diese Data Inchatged im Endeffekt wirklich zu standardisieren, dass man strukturierte und strukturierte Daten gleich gut auch verarbeiten kann?

Daniela Mandl
Ja also ich glaube, es ist eben viel so man man man kann überhaupt Metadaten sammeln und und hinterlegen ja also die man ja dann aus den Inhalten auch generieren kann, aber man muss sich überlegen wie ja also auch bei den unstrukturierten Daten.

Patrick Roith
Mhm.

Daniela Mandl
Gibt's ja oft mal da noch viel, wo man sagt, man kann, man kann ruhig was mitnehmen. Aus diesen Daten, um Sie zu identifizieren und um sie, um sie greifbarer zu machen.

Patrick Roith
Mhm.
Mhm.

Daniela Mandl
Aber ich glaube, man wird dann immer, man wird immer das irgendwie als Metadaten nutzen müssen, würde ich meinen.

Patrick Roith
Mhm ja OK, wenn wir so ein bisschen so zum Ende kommen und Richtung Zukunft schauen wie siehst du die Entwicklung der Datenlandschaft jetzt in den nächsten 2 bis 3 Jahren beziehungsweise auch vielleicht in deinem Aspekt? Wie hast du es jetzt gesehen die letzten 23 Jahre? Was glaubst?

Daniela Mandl
Hm.

Patrick Roith
Wird sich so ein welcher Bereich wird sich da stark entwickeln?

Daniela Mandl
Also ich glaub, das war viel von dem, was wir früher in der Hand quasi programmiert haben. Ersetzen wird können durch Machine Learning Modelle.

Patrick Roith
Mhm.

Daniela Mandl
Wir haben das auch gesehen an einem Projekt, dass wir das mittlerweile nutzen können, dass wir da auch eine bessere Travelquote haben. Man wird trotzdem Menschen brauchen, die.

Patrick Roith
Mhm.
Mhm.

Daniela Mandl
Kontext wissen haben, oder oder terminienspezifisches wissen haben, um Ausreißer beurteilen zu können und damit dann wieder Modelle zu zu zu verbessern. Ja so. Dass.

Patrick Roith
Mhm.

Daniela Mandl
Das an dem wird man nicht vorbeikommen und das ist auch gut so bei einem Gefühl nach.

Patrick Roith
Mhm.
Mhm.

Daniela Mandl
Auch das machen wir bei uns.

Patrick Roith
Mhm.

Daniela Mandl
Also in dem Fall binden wir dann redaktionelle Mitarbeiter ein, um um Ausreißer zu zu hinterfragen und zu zu klassifizieren oder einzuordnen.

Patrick Roith
Mhm.

Daniela Mandl
Ja, es ist halt die die Frage glaube ich langfristig wird die Frage sein, ob ob man irgendwann mal verlernt wie denn so domänenspezifisches wissen funktioniert und wie man sich das aufbaut und behält, wenn man es vielleicht weniger nutzt.

Patrick Roith
Mhm, Mhm, OK.

Daniela Mandl
Also ich glaub, ich glaub das wird eine Challenge sein.
Weil man ohne der Halt dann nicht beurteilen kann, was dann richtig oder falsch ist also.

Patrick Roith
Ja, Mhm, OK und vielleicht auch ein bisschen Hinblick, weil das ja auch zum Teil ein Master Thema ist. Wie siehst du die Zusammenarbeit oder auch die Überschneidungspunkte zwischen eben jetzt dem maxen Team aus dem Real Team?
Und deinem Team, dem Data Integration Team Was ist so? Was sind so die wichtigsten Punkte? Glaubst du, in den nächsten Jahren auch aktuell werden könnten, beziehungsweise was sind, ist auch der Mehrwert vielleicht, den man dann auf beiden Teams eben haben könnte? Was was ist also dein dein Ausblick?

Daniela Mandl
Also ich ich, ich merke, dass Dinge, die wo wir sagen, OK Dinge, die man mit Machine Learning Modellen beurteilen kann, die wir halt vorher eben ausprogrammiert haben, dass die besser sind, ja, sofern man sie dahin trägt also man muss da schon Zeit investieren.

Patrick Roith
Ja.

Daniela Mandl
Man muss, müsste aber auf der anderen Seite bei dem beim Programmieren beim reinen Programmieren ja auch sehr viel Zeit investieren und wir sind einfach zum Schluss gekommen, dass das manchmal das machinearing Modell einfach bessere Quoten.

Patrick Roith
Mhm.

Daniela Mandl
Liefert das ist natürlich spannend, das muss man beurteilen ja was ist die bessere Quote? Und das ist das ist halt das ist enorm wichtig. Ja, dass man sich nicht so sehr drauf verlässt. Blind drauf verlässt das das bringt halt gar nichts, also man bringt vielleicht anstellen wo es keine.

Patrick Roith
Mhm, Mhm.
Ja.

Daniela Mandl
Wichtigkeit hat.

Patrick Roith
Mhm, Mhm.

Daniela Mandl
Was vielleicht tun würde ich niemanden empfehlen, aber ja aber gerade in einem professionellen Kontext würde ich sagen ist das sogar umso wichtiger, ja sich auch zu beurteilen und validieren, ob ob das machinering Modell besser ist oder nicht oder?

Patrick Roith
Ja.
Mhm.
Mhm.

Daniela Mandl
Auch dort wirklich einen sauberen Entwicklungsprozess einzuführen, Versionierung einzuführen, solche Sachen wirklich auch zu unterscheiden. Dieses Modell minus der nächsten und plus der nächsten Version und der übernächsten Version, dass man auch das noch vergleichbar macht, ja.

Patrick Roith
Mhm.
Mhm ja.

Daniela Mandl
Und das wieder darauf aufsetzen können, auch als als Softwareentwickler solche solche

Dinge, das ist oft einmal nicht so, weil das weil das so ein bisschen andere denke ist, wo man sagt OK, man hat da vielleicht eher die Statistiker nicht die Programmierer ja, also das sind ja doch auch unterschiedliche Welten.

Patrick Roith
Mhm.
Mhm, Mhm.
Dann.

Daniela Mandl
Die muss man zusammenbringen, und da gibt es auch unterschiedliche Bedürfnisse, würde ich sagen.

Patrick Roith
Mhm, okay.

Daniela Mandl
Aber ich glaube, wenn man das in Inklung bringt, kann man da sehr viel gewinnen.

Patrick Roith
Ja, okay, okay auch im Bezug vielleicht noch mal nachgefragt auch im Bezug auf Standardisierung von unterschiedlichen Daten? Ich glaube, da hast du ja auch schon gesagt, wenn man mit verschiedenen Modellen arbeitet deprimiert, dann haben wir da sicher einen Mehrwert, aber siehst du das auch, dass da wirklich?
Man sich vielleicht Zeit ersparen könnte et cetera oder dass das ein ein wesentlicher Mehrwert sein könnte.

Daniela Mandl
Eigentlich dadurch, dass man ja paralisieren kann.

Patrick Roith
Ja, Mhm genau Mhm, OK ja.

Daniela Mandl
Kann man sicher sein, auf Zeit, Zeit und vielleicht auch ein Wettbewerbsvorteil sicher arbeiten, würde ich sagen also.

Patrick Roith
Mhm ja, OK.
Super perfekt. Ich glaube, das war jetzt schon relativ zum Ende. Ich schaut es mal ganz kurz durch genau.

Daniela Mandl
Deine Fragen?

Patrick Roith
Aber ich glaub, das waren die die wichtigsten. Gibt es von deiner Seite aus noch irgendein Thema, was dir am Herzen liegt ansonsten?

Daniela Mandl
Ich.

Patrick Roith
Nicht perfekt, sehr gut, dann vielen vielen Dank für die Zeit noch mal und danke auch für die ganzen Insights.

Daniela Mandl
Ja, sehr gerne.

Patrick Roith
Super.

Daniela Mandl
Alles Gute damit.
Hm.

Patrick Roith Transkription beendet